HW2 • CRISP-DM • REGRESSION EXPLORER

# 從特徵選擇到可解釋的預測區間

## Flood 與 King County 迴歸研究室

學號：7114056093 | 更新：2026-10-28

資料、程式、圖表與統計結果均由本次專案實際執行產生。

0.020080　主要模型測試 RMSE
0.844878　主要模型測試 $R^2$
94.97%　95% 預測區間實際涵蓋率

核心發現：20 個原始特徵共同提供訊號。強制刪減會損失預測能力；進階非線性模型雖然更準確，主要模型仍採 LinearRegression，以完成作業所需的解釋與統計分析。

GitHub＋互動網站
下拉切換兩個 Kaggle 題目、比較特徵選擇、解讀預測區間，並支援連接分析服務後輸入自訂 CSV。
本 PDF 是新版作業的補充分析附件。

# 摘要與閱讀導覽

本研究使用 Kaggle Playground Series S4E5 的公開合成資料鏡像，共 1,117,957 筆有標籤樣本與 20 個數值特徵，預測連續目標 FloodProbability。採固定種子切分訓練、校準及獨立測試資料，並在訓練內以五折交叉驗證比較 All Features、SelectKBest、RFE、LassoCV，以及 Ridge、Lasso 和梯度提升。主要 LinearRegression 測試 RMSE 為 0.020080、$R^2$ 為 0.844878；LassoCV 未刪除任何特徵，刪減到 15 欄的線性模型 RMSE 約 0.0324。

Split conformal 以 178,873 筆獨立校準樣本建立 95% 個別預測區間，測試涵蓋率 94.97%，平均寬度 0.080116。殘差存在非正態與異質變異跡象，且分段涵蓋率不足，說明整體達標不能取代局部可靠性分析。

本報告依序呈現研究動機、資料來源、EDA、資料準備、特徵選擇、模型與評估、回歸假設、預測區間、文獻比較、NotebookLM 狀態、GPT 輔助內容、部署、結論、參考來源與附錄。所有測試比較均於模型設定鎖定後執行，不據此重選模型。

新版以 GitHub 與網站為主要繳交。本報告保留 Flood 完整統計研究，並補充 King County 房價分析、兩題互動網站與自訂 CSV 流程；PDF 與對話列為補充附件。原始輸入分別 20 與 19 欄，均符合 >13、<40，也符合較早的 10～20 欄條件。

關鍵詞：多元線性回歸、特徵選擇、資料洩漏、CRISP-DM、Split conformal。

# 01｜研究動機與 Business Understanding

預測 FloodProbability 的教育價值在於：把多個環境與基礎設施評分轉換成連續目標估計，練習比較變數貢獻、評估誤差並量化不確定性。可用於合成資料的情境比較、分析教學與模型流程驗證。資料缺少真實地理、時間與觀測事件的獨立驗證，因此不能直接用於疏散決策或真實洪災風險定價。

Multiple Linear Regression 提供明確的加法模型、係數與殘差，能建立透明基準，並檢查特徵選擇是否真的改善泛化。輸入是 20 個評分型數值特徵；輸出是資料集定義的 FloodProbability，不是二元洪災分類標籤。

成功標準：在不使用測試資料調參的前提下，最小化訓練內 CV RMSE，再以獨立測試集報告 MAE、MSE、RMSE 與 $R^2$；同時呈現 95% 區間的實際涵蓋率及寬度。並不事先假設所有特徵都必要，也不預設高複雜度模型一定更好。

| CRISP-DM 階段 | 本研究產出 |
| --- | --- |
| Business Understanding | 研究目標、適用界線與成功標準 |
| Data Understanding | 真實 CSV 稽核、分布與相關性 |
| Data Preparation | 互斥資料切分、Pipeline、輸入驗證 |
| Modeling | 特徵選擇與五折 CV，鎖定主要模型 |
| Evaluation | 獨立測試、殘差與預測區間 |
| Deployment | GitHub、網站、API、joblib 與 Notebook |

# 02｜Dataset Description 與來源

原始競賽：[S01] Regression with a Flood Prediction Dataset，Kaggle Playground Series S4E5。官方競賽下載 API 回應 401，因此改用 Kaggle 公開鏡像 [S02] johnwicknice/playground-series 的 version 1。下載檔名、CSV 結構與預期競賽筆數吻合；保存 SHA-256，但沒有可供逐位元比對的官方檔案，因此不宣稱完成官方雜湊核對。

官方將 Playground 定義為合成資料練習。本專案沒有自行合成或改寫原始資料。原始生成模型的架構、參數及完整生成程式未取得，不能以欄名推定實際物理量或因果機制。鏡像 API 標示 Apache 2.0，更新時間 2024-05-18；鏡像標記不自動取代原競賽條款。rules 動態頁未完整可讀，正式提交或外部再發布前需確認原始規則。

| 項目 | 稽核結果 |
| --- | --- |
| 有標籤 train.csv | 1,117,957 列 × 22 欄 |
| 官方 test.csv | 745,305 列 × 21 欄 |
| 原始有效特徵 | 20（排除 id 與 Target） |
| Target | FloodProbability |
| 缺失／無限值 | 0 / 0 |
| 重複輸入列 | 0 |
| 型別 | 20 個 int64；Target float64 |
| 輸入尺度 | 觀測範圍 0～19；未定義物理單位 |
| 目標範圍 | 0.285～0.725 |

無類別特徵，因此不建立類別編碼。ID 僅用於識別與 Kaggle 提交，不是模型輸入。官方 test.csv 沒有 Target，與本研究從 train.csv 保留的測試集不同。

# 03｜Data Understanding：目標與欄位

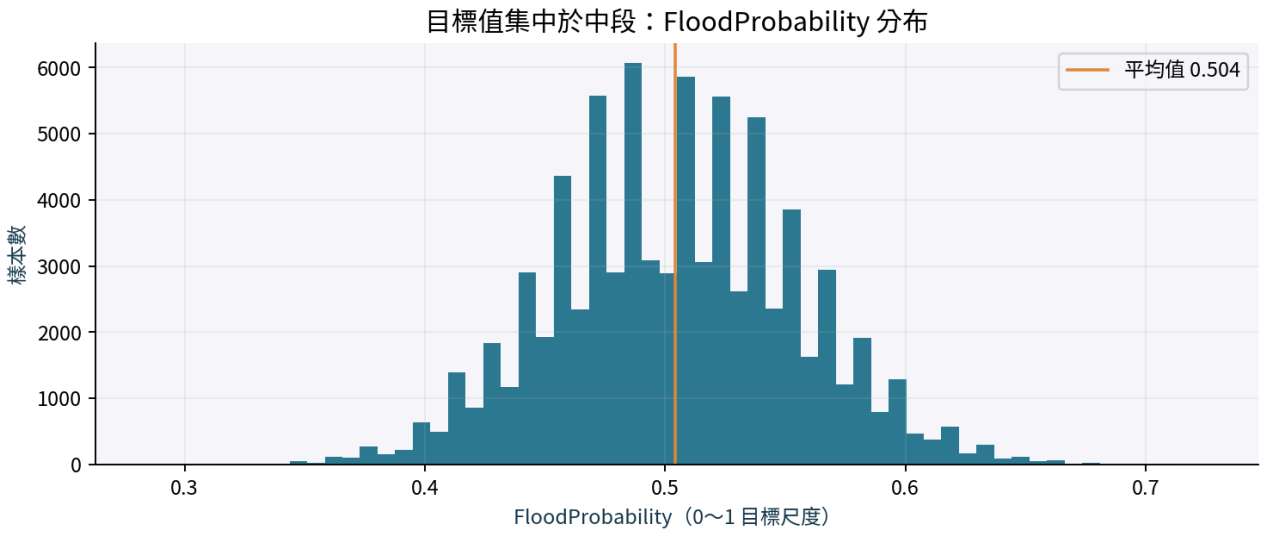



圖 1。訓練子樣本的目標分布。評分集中於中段，不代表現實世界的洪災盛行率。

全部 EDA 圖使用固定的訓練子樣本 80,000 筆；散點圖再抽樣 2,500 筆，以減少重疊。資料完整性稽核則讀取全部 CSV。描述統計見 descriptive_statistics.csv，包含 count、mean、std、min、四分位與 max。

| 代碼 | 原始欄名 | 代碼 | 原始欄名 |
|---|---|---|---|
| F01 | MonsoonIntensity | F11 | IneffectiveDisasterPreparedness |
| F02 | TopographyDrainage | F12 | DrainageSystems |
| F03 | RiverManagement | F13 | CoastalVulnerability |
| F04 | Deforestation | F14 | Landslides |
| F05 | Urbanization | F15 | Watersheds |
| F06 | ClimateChange | F16 | DeterioratingInfrastructure |
| F07 | DamsQuality | F17 | PopulationScore |
| F08 | Siltation | F18 | WetlandLoss |
| F09 | AgriculturalPractices | F19 | InadequatePlanning |
| F10 | Encroachments | F20 | PoliticalFactors |

# 04｜Data Understanding：特徵分布

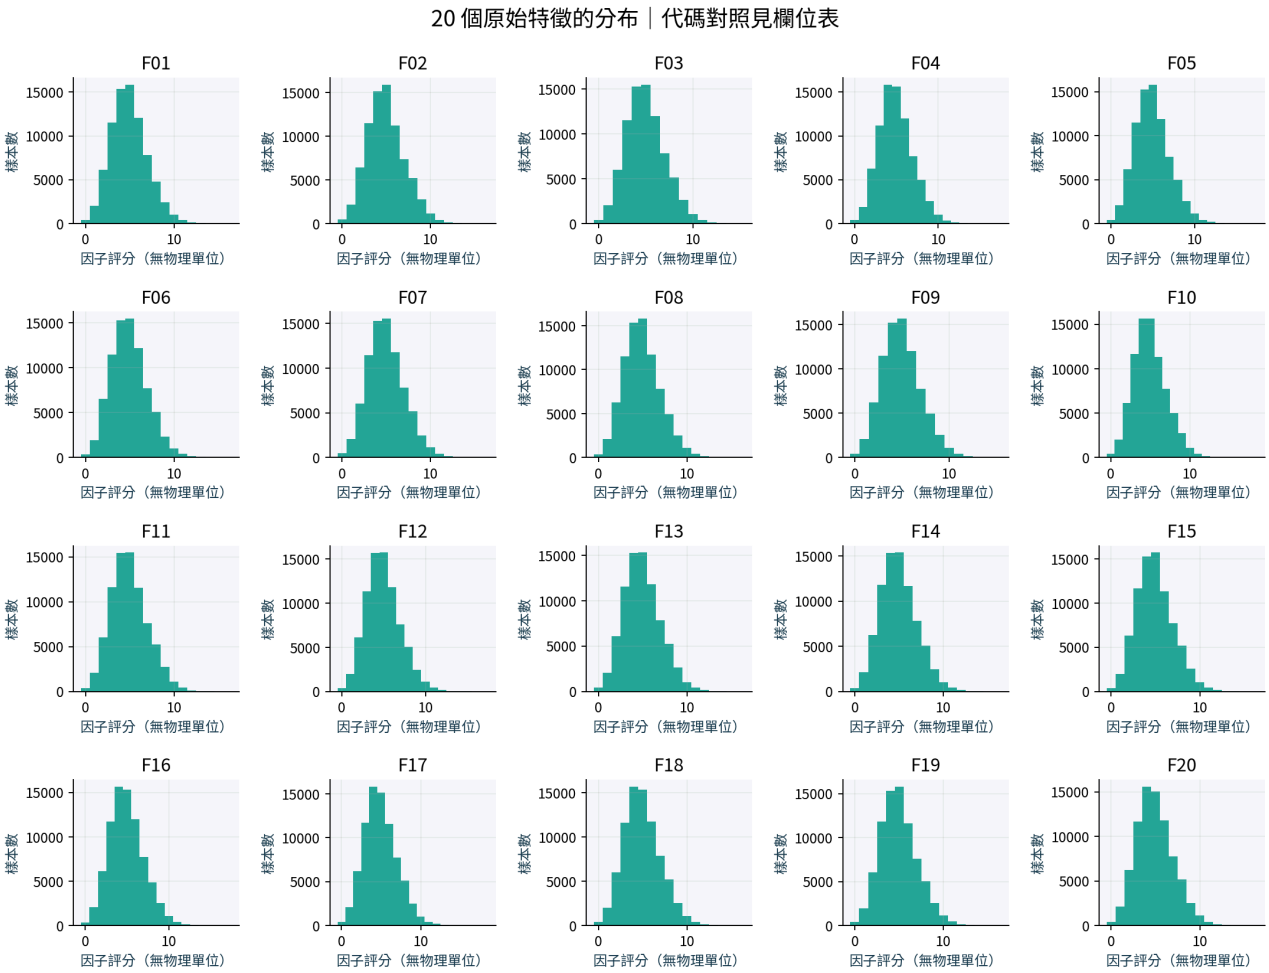



圖 2。20 個原始因子的直方圖；F01～F20 對照前頁。橫軸均為資料提供的評分，縱軸為樣本數。

特徵均為整數評分，分布存在離散性與尾端樣本。分布形狀不足以辨認資料的實際生成機制；未提供物理單位，因此不以雨量、面積或機率替代原始評分。

# 05｜Data Understanding：相關性與離群值

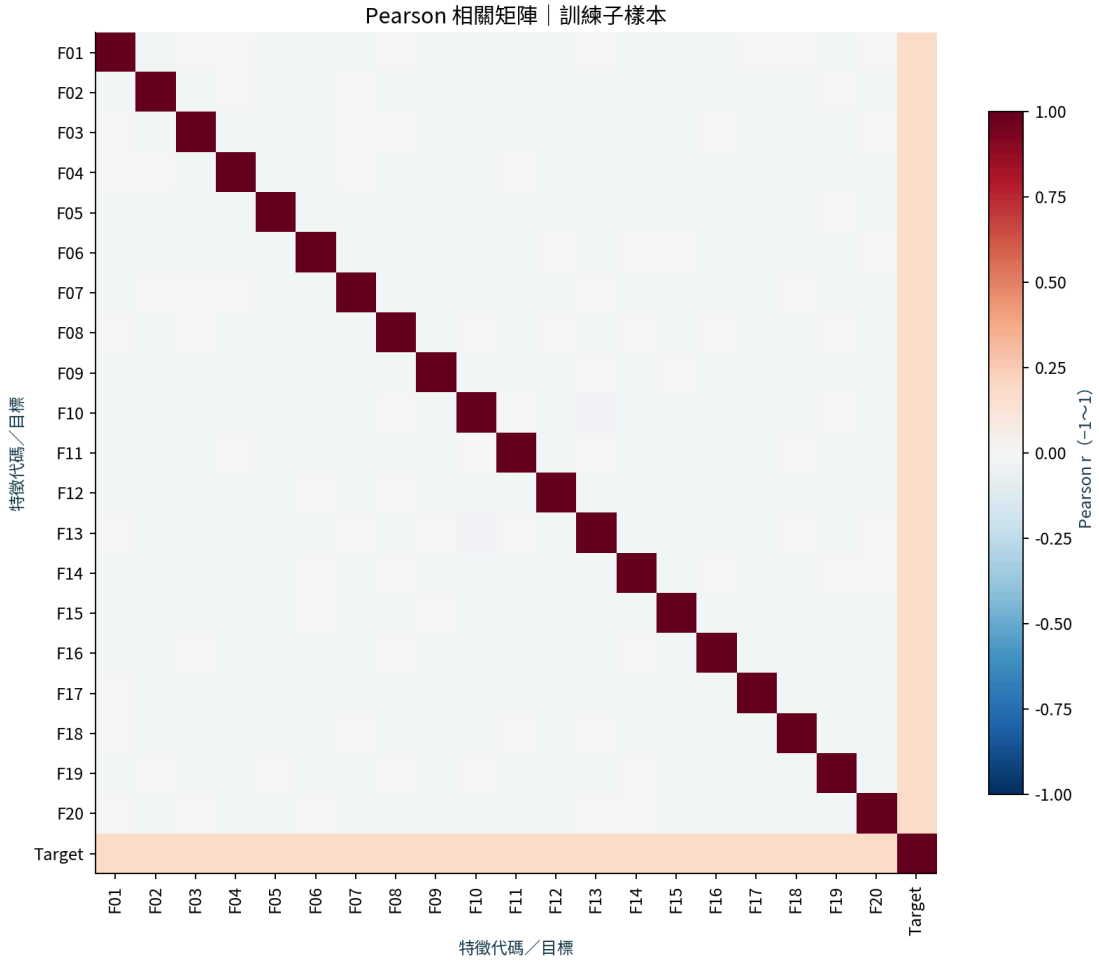



圖 3。Pearson 相關矩陣。特徵間相關很弱，但各特徵可共同累積預測訊號。

特徵間最大絕對相關為 0.0243，最大 VIF 為 1.0043，未見嚴重線性共線性。這支持「弱相關的多個特徵共同貢獻」的解讀，不能據此宣稱因果獨立。Pearson 檢查只反映線性關係，且不直接用全資料相關排序選擇模型。

# 06｜Data Understanding：趨勢與尾端

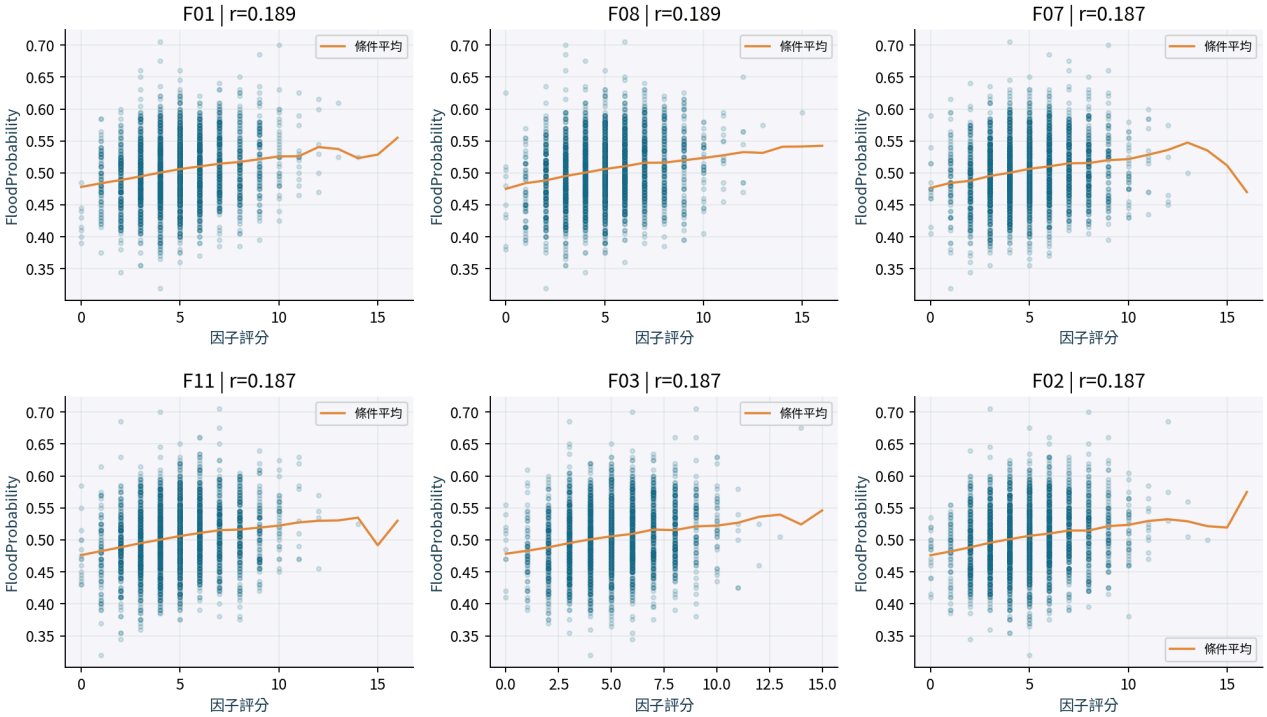



圖 4。訓練內與 Target 絕對相關最高的六個特徵；橘線為相同評分的平均 Target。尾端樣本較少，均值較不穩定。

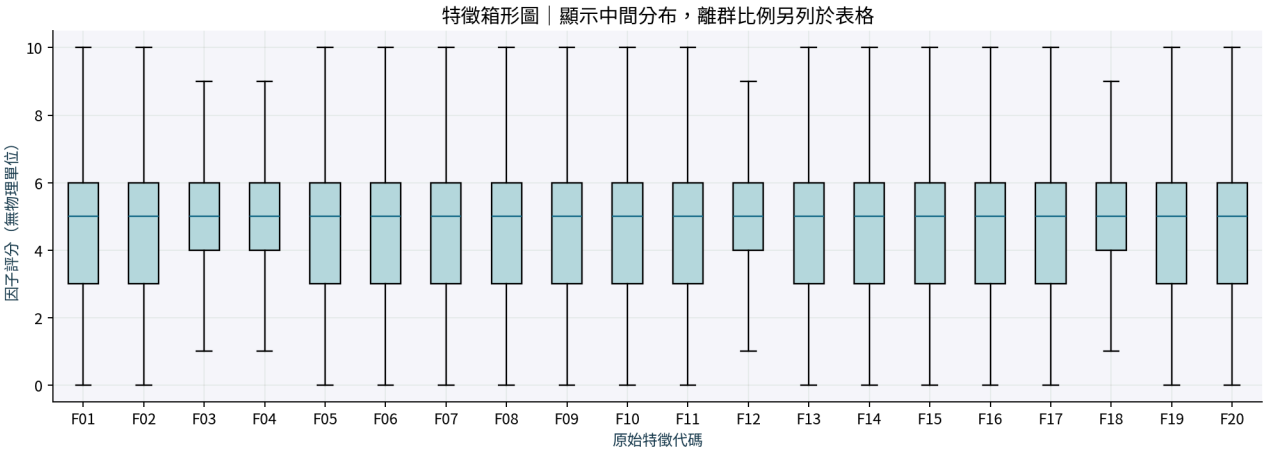



圖 5。箱形圖為易讀性隱藏離群點；離群比例依訓練 IQR 另存 outlier_analysis.csv。沒有以任意規則刪除尾端樣本。

IQR 外觀測不等於錯誤資料。未發現負值、無限值或非法型別，因此保留離群觀測，讓獨立測試反映完整分布；未利用測試誤差決定刪除規則。

# 07｜Data Preparation 與防洩漏設計

| 資料角色 | 筆數 | 用途 |
| --- | --- | --- |
| 完整有標籤資料 | 1117957 | 僅資料稽核；提交專用模型可全量重訓 |
| 主要訓練部分 | 715492 | 最終候選模型擬合 |
| 獨立校準集 | 178873 | 只估計區間誤差分位數 |
| 本地獨立測試集 | 223592 | 模型鎖定後一次性診斷 |
| CV 訓練內子樣本 | 80000 | 方法／參數選擇與 EDA |
| 官方無標籤測試集 | 745305 | 只產生 submission.csv |

採 random_state=42。先切分 80% development / 20% testing，再將 development 的 20% 留作 calibration，實際比例為約 64%／16%／20%。三組索引保存為 splits.npz，並檢查 ID、列索引及完全重複輸入的互斥性。CV 子樣本不超出真正訓練集合。

一般流程為 median imputer → StandardScaler → selector → model，每一 fold 都 clone 並重新 fit。資料沒有缺失，因此 imputer 是部署防護，不改變本次完整數值。標準化對純 OLS 的預測不構成必要條件，但利於 Ridge／Lasso 的懲罰與標準化係數比較。沒有類別資料，不強加編碼。

LassoCV 篩選流程特殊處理為 selector → imputer → scaler → LinearRegression。因本資料無缺失、原始特徵同屬評分尺度，LassoCV 直接在原始 X 進行三折內層選擇，避免把整個 outer fold 的 scaler 估計帶入 inner fold。若未來訓練資料有缺失或異質單位，須改用內層完整 Pipeline 搜尋，不能直接沿用此篩選流程。

先保存 selection_lock.json，才計算測試預測。校準集不參與任何 selector、scaler、超參數或模型選擇；測試集也不參與區間寬度設定。

# 08｜Feature Selection：設計與 CV

All Features 為 20 欄基準。SelectKBest 以 f_regression 衡量單變量線性關聯；RFE 以 LinearRegression 係數遞迴刪除、step=5。兩者各測試 5、10、15 欄。LassoCV 使用 12 個 alpha（$10^{-5}$ 至 10 $^{2}$），內層三折，依非零係數篩選後再做 OLS。[S03–S05]

| 候選模型 | 平均保留數 | CV RMSE | 折間 SD |
|---|---|---|---|
| LR_All | 20 | 0.020181 | 0.000061 |
| LR_KBest_5 | 5 | 0.046224 | 0.000222 |
| LR_RFE_5 | 5 | 0.046287 | 0.000274 |
| LR_KBest_10 | 10 | 0.040316 | 0.000145 |
| LR_RFE_10 | 10 | 0.040378 | 0.000194 |
| LR_KBest_15 | 15 | 0.032437 | 0.000126 |
| LR_RFE_15 | 15 | 0.032349 | 0.000073 |
| LR_LassoSelect | 20 | 0.020181 | 0.000061 |
| Ridge_0.1 | 20 | 0.020181 | 0.000061 |
| Ridge_10 | 20 | 0.020181 | 0.000061 |
| Ridge_1000 | 20 | 0.020201 | 0.000054 |
| Lasso_1e-05 | 20 | 0.020181 | 0.000060 |
| Lasso_0.0001 | 20 | 0.020187 | 0.000057 |
| Lasso_0.001 | 20 | 0.020793 | 0.000060 |
| HGB_Summary | 20 | 0.018732 | 0.000061 |

共同外層設計：KFold(n_splits=5, shuffle=True, random_state=42)，樣本數 80,000。CV SD 為五折誤差的標準差，不是獨立樣本信賴區間。此表用於模型選擇，選定模型的 CV 估計可能偏樂觀；最終泛化由獨立測試集評估。

主要模型在 LinearRegression 家族中依 CV RMSE 最小值選擇。All 與 LassoSelect 產生相同結果時依固定候選順序保留 All。進階比較模型的整體 CV 更佳，但不取代作業主要線性模型。

# 09｜Feature Selection：結果與解釋

| 方法 | 數量 | 最終完整訓練部分選用欄位 |
|---|---|---|
| LR_All | 20 | F01, F02, F03, F04, F05, F06, F07, F08, F09, F10, F11, F12, F13, F14, F15, F16, F17, F18, F19, F20 |
| LR_KBest_15 | 15 | F01, F02, F03, F04, F06, F07, F08, F09, F11, F14, F16, F17, F18, F19, F20 |
| LR_RFE_15 | 15 | F02, F03, F05, F07, F08, F10, F11, F12, F13, F14, F15, F17, F18, F19, F20 |
| LR_LassoSelect | 20 | F01, F02, F03, F04, F05, F06, F07, F08, F09, F10, F11, F12, F13, F14, F15, F16, F17, F18, F19, F20 |

各 CV fold 的選中名稱與分數完整保存於 cv_folds.csv；本頁列出完整訓練部分擬合後的名稱代碼。訓練子樣本與完整訓練的排序可不同，因許多特徵的效果接近，不能把微小排序差距當成穩定的因果重要性。

LassoCV 最佳 alpha=1e-05，保留 20 欄，沒有任何係數壓成零。它不保證固定特徵數。最終保留 All 並非忽略 Feature Selection，而是實驗顯示刪減會損失累積訊號；最少 5 欄至 15 欄的方案都已實際比較。

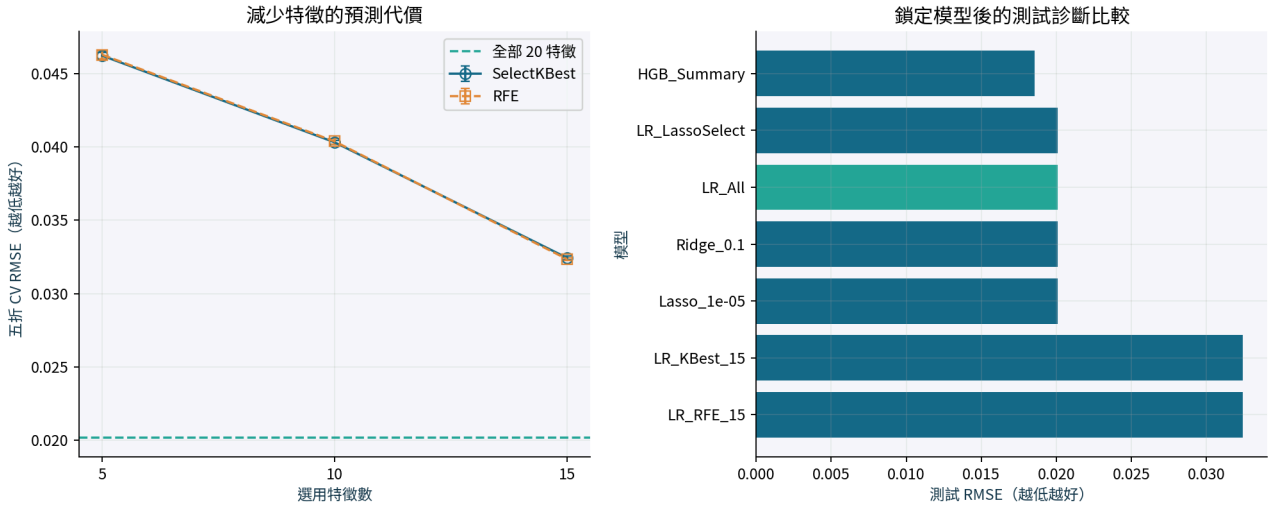



圖 6。左：特徵數與 CV RMSE，誤差棒為折間 SD。右：鎖定模型後的測試診斷，僅用於比較，不據此重選主模型。

# 10｜Modeling：模型與方程式

主要模型 $\hat{y} = \beta_0 + \Sigma_j \beta_j x_j$；使用 sklearn.linear_model.LinearRegression，含截距。Ridge 比較 alpha={0.1,10,1000}；Lasso 比較 alpha={$10^{-5}$,$10^{-4}$,$10^{-3}$}。Ridge 懲罰係數平方和，Lasso 懲罰絕對值和；不同 estimator 的損失正規化不同，alpha 數字不能直接相互比較。[S04]

進階模型為 HistGradientBoostingRegressor，加入每筆輸入的 sum 與 std，原始輸入 20 欄、模型內部 22 欄。固定 max_iter=140、max_leaf_nodes=15、learning_rate=0.08、l2_regularization=10、early_stopping=False。只作單一合理設定比較，未宣稱充分調參或達到最佳可能分數。其衍生特徵不含 Target，也不估計跨樣本參數。

主要模型使用 715,492 筆擬合，截距（原始尺度）為 -0.05294076。例如 MonsoonIntensity 增加 1 評分、其他欄位固定時，預測增加約 0.005613；這是模型內條件關聯，不是因果效應。

| 特徵代碼 | 原始係數 | 標準化係數 |
|---|---|---|
| F01 | 0.005613 | 0.011557 |
| F02 | 0.005638 | 0.011807 |
| F03 | 0.005663 | 0.011739 |
| F04 | 0.005674 | 0.011636 |
| F05 | 0.005658 | 0.011770 |
| F06 | 0.005653 | 0.011623 |
| F07 | 0.005649 | 0.011769 |
| F08 | 0.005635 | 0.011650 |
| F09 | 0.005629 | 0.011633 |
| F10 | 0.005642 | 0.011759 |
| F11 | 0.005643 | 0.011721 |
| F12 | 0.005633 | 0.011677 |
| F13 | 0.005662 | 0.011826 |
| F14 | 0.005643 | 0.011721 |
| F15 | 0.005638 | 0.011734 |
| F16 | 0.005608 | 0.011577 |
| F17 | 0.005678 | 0.011782 |
| F18 | 0.005635 | 0.011654 |
| F19 | 0.005613 | 0.011679 |
| F20 | 0.005644 | 0.011798 |

完整數值見 coefficients.csv。標準化係數表示特徵增加一個訓練標準差的目標變化；不直接以原始係數排序重要性。

# 係數視覺化與推論界線

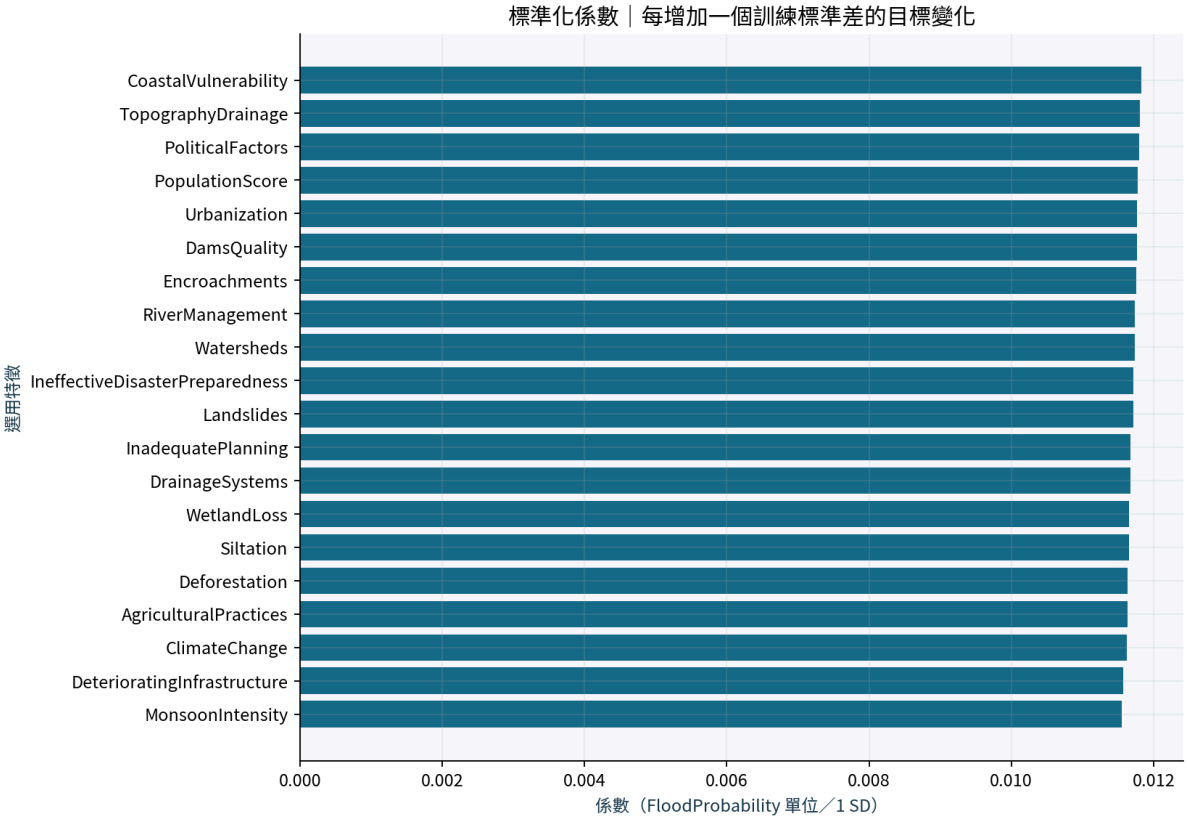



圖 6a。係數依標準化效果排列，數值接近；圖上的微小差距不能視為實質重要性或因果證據。

每個係數皆是在其他欄位固定時的條件關聯。合成資料的命名不提供因果識別；例如係數為正，不代表對該項設施進行真實介入就會增加洪災。估計誤差、資料生成過程及遺漏變數均會限制推論。

ols_hc3_inference.csv 另列訓練子樣本 OLS 的 robust 標準誤與區間。主模型在更大的訓練部分擬合，兩者用途不同；不把子樣本推論表誤標成完整主模型的參數區間。

# 11｜Evaluation：指標與模型比較

設殘差 $e_i=y_i-\hat{y}_i$、n 為本地測試樣本數：$MAE=\Sigma|e_i|/n$；$MSE=\Sigma e_i^2/n$；$RMSE=\sqrt{MSE}$；$R^2=1-\Sigma e_i^2/\Sigma(y_i-\bar{y})^2$。MAE／RMSE 的單位與 Target 相同；MSE 為平方單位；$R^2$ 無單位且可能小於零。

Adjusted $R^2=1-(1-R^2)(n-1)/(n-p-1)$，本地測試 n=223,592、主要 OLS p=20，結果為 0.844864。僅在線性模型 n>p+1 時提供此代入值；測試集上的 adjusted $R^2$ 是描述性指標，並不恢復選模後的無偏性。Ridge／Lasso／HGB 的有效自由度未估計，因此不套用名目欄數強行計算。

| 模型 | 原始欄數 | MAE | MSE | RMSE | $R^2$ |
|---|---|---|---|---|---|
| LR_All | 20 | 0.015795 | 0.000403 | 0.020080 | 0.844878 |
| LR_KBest_15 | 15 | 0.026089 | 0.001051 | 0.032414 | 0.595791 |
| LR_RFE_15 | 15 | 0.026111 | 0.001051 | 0.032425 | 0.595506 |
| LR_LassoSelect | 20 | 0.015795 | 0.000403 | 0.020080 | 0.844878 |
| Ridge_0.1 | 20 | 0.015795 | 0.000403 | 0.020080 | 0.844878 |
| Lasso_1e-05 | 20 | 0.015798 | 0.000403 | 0.020080 | 0.844876 |
| HGB_Summary | 20 | 0.014497 | 0.000344 | 0.018559 | 0.867484 |

以上全部為實際測試結果，各方法代表方案先由 CV 決定。多組測試值屬事後診斷，沒有依此再搜尋或選擇最終方案。Ridge 與 OLS 幾乎一致，不應把小數尾端差異描述為實質改善。

進階 HGB + summary 的 RMSE 為 0.018559，比主模型降低 7.57%；這是本次固定設定與獨立切分的結果，不代表所有分布或真實災害情境下同樣優越。

# 12｜Evaluation：預測與失敗案例

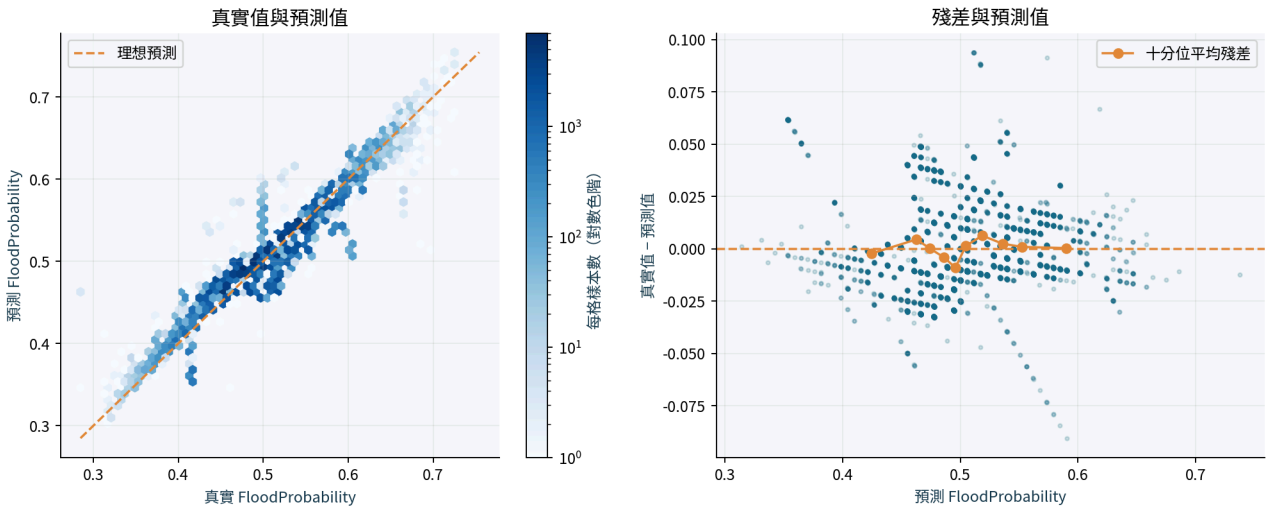



圖 7。左為完整測試集 hexbin 密度，避免重疊遮蔽。右以固定抽樣呈現殘差，橘線顯示十分位平均誤差。

理想預測落在對角線附近，但殘差圖呈現結構性起伏，表示簡單加法模型仍未充分捕捉合成資料的非線性。此為診斷結果，未據以回頭調整本次主模型。

| 樣本 ID | 真實值 | 預測 | 絕對誤差 |
|---|---|---|---|
| 242964 | 0.285000 | 0.466375 | 0.181375 |
| 331323 | 0.285000 | 0.466138 | 0.181138 |
| 620002 | 0.695000 | 0.516872 | 0.178128 |
| 679010 | 0.285000 | 0.460659 | 0.175659 |
| 593506 | 0.285000 | 0.460565 | 0.175565 |

表中為鎖定模型後誤差最大的五筆，非資料清理依據。完整十五筆見 failure_cases.csv；不因它們偏離模型就刪除。下一輪研究可另設新驗證資料，探索非線性、異質誤差與資料生成規律。

# 13 | Regression Assumption Analysis

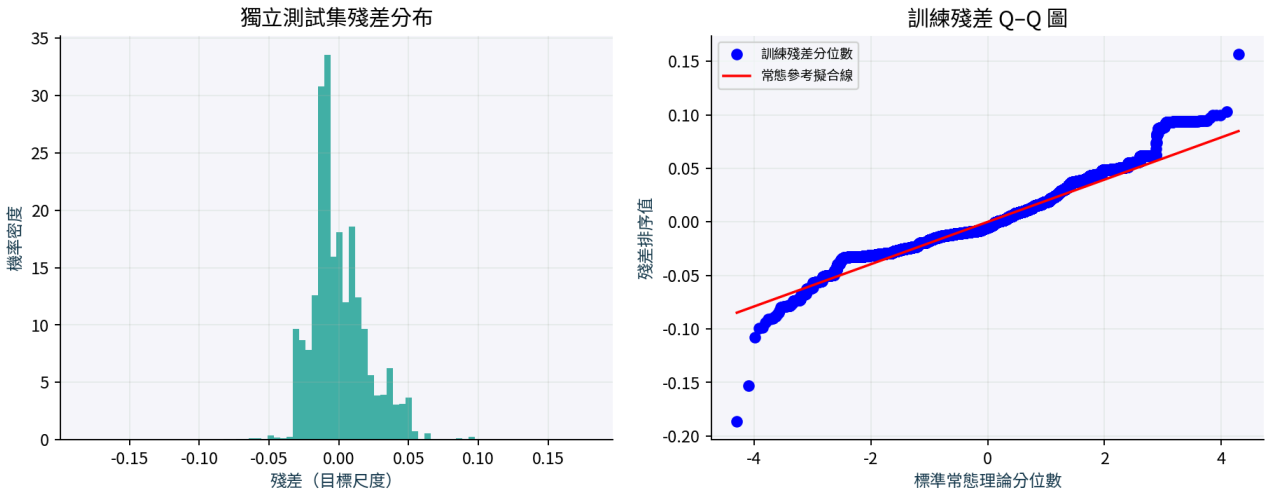



圖 8。測試殘差分布與訓練殘差 Q–Q 圖。尾部及偏斜偏離常態；大樣本下應同時看圖與效果量。

| 檢查 | 數據／判讀 |
|---|---|
| Linearity | 殘差分段平均有系統性波動，線性近似不完全充分 |
| Independence | DW=2.0027；無自然時間順序，不能證明獨立 |
| Homoscedasticity | BP LM=3464.68，p 極小；拒絕同質變異 |
| Normality | JB=10280.3，偏度=0.705，峰度=4.047 |
| Multicollinearity | 最大 VIF=1.0043，未見嚴重共線性 |

BP／JB 在浮點輸出中 p=0 是數值下溢，不代表真正機率精確為零。80,000 筆使檢定對微小偏差敏感，但圖形也顯示實質結構。DW 使用隨機排列的截面資料，只是描述，沒有時序解釋。交換性／獨立性無法單靠殘差檢定證明。

異質變異使傳統同質 OLS 標準誤失準；本研究另提供 HC3 robust 係數標準誤及 95% 區間。HC3 不修正函數形式錯誤、未觀測混淆或選模後推論。該表只針對訓練子樣本、條件於已選特徵的探索性推論，不等於主要模型全量係數的正式確認性檢定。

# 14｜Prediction Interval：方法與結果

採 split conformal prediction [S06]。先固定模型，再用 calibration residual $s_i=|y_i-f(x_i)|$；令 m 為校準樣本數，$k=\text{ceil}((m+1)\times 0.95)$，取第 k 個排序誤差 q。新樣本的個別預測區間為 $[f(x)-q, f(x)+q]$。這是包含個別新觀測值的 Prediction Interval，不是條件平均值的 Confidence Interval。

| 項目 | 結果 |
|---|---|
| Nominal coverage | 95% |
| 校準筆數 m | 178873 |
| 有限樣本排序 k | 169931 |
| 半寬 q | 0.04005815 |
| Empirical test coverage | 94.9667% |
| Average interval width | 0.08011631 |
| 點預測超出 0～1 | 0 |
| 下界／上界超出 0～1 | 0 / 0 |

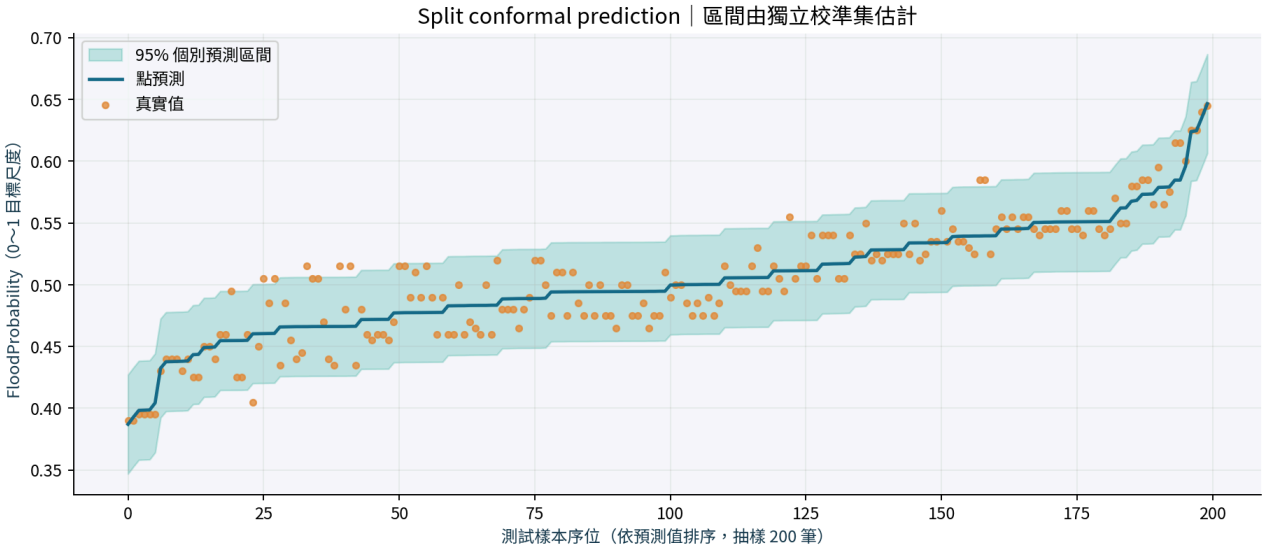



圖 9。從測試集固定抽樣 200 筆，再依預測值排序，同步排列真實值與上下界。固定半寬來自校準誤差分位數，不是任意 ±5%。

未裁切點預測或上下界，本次都落在 0～1。線性模型仍可能在新輸入上超出目標範圍；任意裁切會改變預測與區間的解讀。交換性與校準／測試分布一致時提供邊際涵蓋保證，不要求常態與等變異；分布轉移、相依樣本或局部風險子群則不保證。

# 15｜Prediction Interval：局部不足與限制

| 依預測值分組 | 筆數 | RMSE | 區間涵蓋率 |
|---|---|---|---|
| (0.302, 0.455] | 22360 | 0.021776 | 0.882513 |
| (0.455, 0.466] | 22359 | 0.028161 | 0.845879 |
| (0.466, 0.478] | 22359 | 0.025991 | 0.952234 |
| (0.478, 0.494] | 22359 | 0.018193 | 0.998614 |
| (0.494, 0.5] | 22359 | 0.018320 | 0.999821 |
| (0.5, 0.511] | 22359 | 0.017897 | 0.970482 |
| (0.511, 0.528] | 22359 | 0.020912 | 0.939443 |
| (0.528, 0.54] | 22359 | 0.016416 | 0.947225 |
| (0.54, 0.568] | 22359 | 0.013604 | 0.970437 |
| (0.568, 0.754] | 22360 | 0.014509 | 0.990027 |

整體涵蓋率為 94.97%，但十分位分組最低只有 84.59%。整體接近 95% 並不意味每個預測區段都可靠。

此分組僅為事後診斷，沒有用測試集重新調整區間。固定絕對殘差區間在低誤差區段偏寬，在高誤差區段可能不足。若要改善，可在全新實驗中使用局部尺度化 conformal 或 conformalized quantile regression，並另行保留校準／測試資料；不能直接根據本表擴張區間再稱為未見資料評估。

本次主要限制包括：合成資料的外部效度、沒有時間與地區資訊、內部 CV 只用固定 80,000 筆、有限 alpha 搜尋、未對超參數選擇作完整 nested-CV 效能估計，以及線性模型無法保證輸出有界。獨立測試提供主要泛化估計，但不替代真實地區或時間外驗證。

# 16 | Comparison with Existing Approaches

| 方法 | 優點 | 限制 | 本研究比較 |
|---|---|---|---|
| Linear Regression | 係數清楚、容易重現 | 函數形式與有界性受限 | 主要 RMSE 0.020080 |
| Ridge | L2 可穩定相關變數 | 不會直接刪欄 | 與 OLS 幾乎相同 |
| Lasso／LassoCV | L1 可稀疏化 | 選擇依 alpha 與尺度而變 | 選中 alpha 未刪任何欄 |
| HGB + summary | 捕捉非線性與整體訊號 | 解釋與運算成本較高 | 實測 RMSE 0.018559 |
| AutoGluon／集成 | 整合多模型、適合競賽探索 | 資源與調參成本較高 | 僅文獻比較，沒有實作或自稱排名 |

上述優缺點為 [S03–S06] 的理論與本實驗的綜合解讀；S4E5 參賽者 [S08] 分享列內總和／標準差特徵，本研究因此預先設計 HGB 比較。AutoGluon 維護者 [S09] 列出該競賽的成功案例，只證明該類解法值得研究，不是本作業的實測表現。

視覺呈現參考 scikit-learn 範例 [S10] 的方法比較原則：統一座標、明示誤差與清楚圖例。本報告全部數值圖均由本次執行結果自行產生；沒有移用別人的圖形數據或排行榜截圖。

# 17｜NotebookLM 摘要

PASS：研究附件、摘要與來源已確認
使用者提供 13 頁研究整理，並確認匯入原 sources.md 的 S01–S10 網址。

使用者提供的 NotebookLM 研究整理指出，線性模型應依資料維度、共線性、離群值與計算資源選用。OLS 最小化殘差平方和，便於解釋各輸入與連續目標的關聯；Ridge 加入 L2 懲罰以縮減係數，Lasso 加入 L1 懲罰，可能產生零係數，因此可作特徵篩選。特徵選擇方面，SelectKBest 依單變量分數排序，RFE 反覆擬合並剔除較弱特徵，Lasso 則依正則化強度決定稀疏程度，不能保證固定保留數量。研究亦強調，補值、標準化與特徵選擇必須封裝於 Pipeline，並只在每個交叉驗證訓練折擬合；測試資料僅套用既有轉換，以避免資料洩漏。分位數回歸可估計不同條件分位數，值得作為異質變異資料之區間方法比較，但其實際涵蓋率仍須另外驗證。以上整理對應所提供 PDF 第 2–4、9–13 頁，概念經官方文件 [S11–S13] 核對；使用者已確認研究使用原來源清單 S01–S10；本文引用編號為整合時後補，並非原 PDF 的逐句引用標記。

摘要依使用者提供的 NotebookLM 研究文件 [S14] 整理，並由 AI Coding Agent 核對技術內容；不是逐字原始回答。原 PDF 完整保留於 research/notebooklm_chat.pdf。來源對應為後補核對，不冒稱原生引用標記。

收件與來源確認：2026-10-20。實際操作日期與 notebook 連結未提供，保持空白；不把收件日期當成研究日期。來源核對紀錄見 research/document_integration_review.md。

# 17B｜研究核對與本作業的連結

| 研究重點 | 來源對應 | 本作業如何使用 |
| --- | --- | --- |
| OLS／Ridge／Lasso | 原 S04；核對 S11 | 比較相同切分與尺度下的模型 |
| KBest／RFE／L1 選擇 | 原 S03；核對 S12 | 5／10／15／All 經 CV 比較 |
| Pipeline／防洩漏 | 原 S05；核對 S13 | 各 fold 獨立 fit；測試只 transform |
| 分位數與區間 | 原 S04；延伸 S06 | 主要實作獨立校準的 split conformal |

與實驗的關係：LassoCV 保留 20 欄，顯示 L1 不保證刪除特徵。刪減至 15 欄的 KBest／RFE RMSE 約 0.0324，高於全部欄位 OLS 的 0.020080；Ridge／Lasso 改善有限。HGB 的 0.018559 是本專案實測比較，不是 NotebookLM 或他人排行榜分數。

技術修正：原文件討論的 SGDClassifier 與 LogisticRegression 求解器屬分類脈絡，不能直接當作 FloodProbability 回歸模型；newton-cholesky 不是本次 LinearRegression 的參數。OLS 求解本身不要求常態誤差；常態性涉及特定推論方法。分位數區間亦不能未驗證便宣稱 95% 涵蓋。

流程修正：原文件有全資料先標準化的示範，不能直接拿來評估內層 CV。本專案沿用已驗證的 fold-local 流程。固定種子只在相同資料與環境下支持重現，不承諾跨套件版本逐位元一致。

> 研究附件提供方法脈絡；實驗表格提供本作業證據。兩者分開標示。未採用原文無條件的「最快」「必須」「首選」斷言；分類 accuracy 範例不當作本次回歸評分。

# 18｜GPT 輔助內容

使用者已提供 research/chatgpt_raw_session.pdf，為瀏覽器匯出的 40 頁原始 ChatGPT 對話，從作業規定與題目選擇，到完整實作提示詞與匯出說明。舊的 4 頁整理稿 [S15] 仍保留作輔助文件，不再充當原始對話證據。

本次 AI Coding Agent 實際協助：資料與文獻查找、Python 專案、CSV 稽核、切分與 Pipeline、Feature Selection、模型、統計檢定、Conformal、圖表、部署、測試、Notebook、PDF、圖表檢閱、學號與研究文件整合，以及本輪公開對話的逐字匯出。所有實驗數值來自實際執行。

> 完整 GPT 對話：PASS：原始對話已合併（截至匯出時間）
> 附錄含 ChatGPT 原始 PDF 與本輪 Codex 公開訊息；獨立合併檔為 report/gpt_conversation.pdf。

本輪 Codex 擷取 43 則使用者與助理公開訊息，截止 2026-10-20T07:12:46.685Z（UTC）。原文以 JSON 保存，逐則 SHA-256 與 PDF 抽取文字核對；ChatGPT 原頁保留並以文字及像素核對。

匯出範圍是使用者提供的前續對話與本次 HW2 的公開文字，包含進度回覆；不含系統指令、內部推理與工具原始輸出。歷史訊息的舊狀態按原文保留，不用事後結論改寫。截止之後的新訊息可再追加；完整性證據見 conversation_export.json。

來源與原文不等於所有歷史建議都正確。最終方法與數據以本報告及實際驗收結果為準；作者仍須理解方法並對提交內容負責。

# 19｜Deployment 與 Kaggle 提交

predict_new_data(input_data) 接受 DataFrame、單筆字典或 CSV 路徑；檢查必要欄位、重複欄名、數值型別與無限值。多餘欄位如 id 被忽略。缺失值以已擬合訓練中位數補值並提出警示；超過訓練觀測範圍則提醒外推。函式返回 prediction、lower_95、upper_95。

```
from src.prediction import predict_new_data
result = predict_new_data("data/processed/new_samples.csv")
print(result)
```

| prediction | lower_95 | upper_95 |
|---|---|---|
| 0.573548 | 0.533490 | 0.613606 |
| 0.455261 | 0.415203 | 0.495320 |
| 0.454875 | 0.414817 | 0.494933 |
| 0.466213 | 0.426155 | 0.506271 |
| 0.466140 | 0.426081 | 0.506198 |

主要模型檔 outputs/models/primary_bundle.joblib 包含完整 Pipeline、原始欄位、訓練範圍與 conformal q。模型載入後預測與原模型一致；只載入本專案可信來源的 joblib 檔。

另以全部有標籤資料重訓相同鎖定方法，存成 submission_pipeline.joblib 並預測官方 745,305 筆資料。此模型不能宣稱保有原本獨立測試評分，也不能沿用原校準區間。submission.csv 格式為 id,FloodProbability，已與官方範例逐列核對 ID。

官方競賽已結束，查閱時頁面仍顯示 Late Submission。是否可晚交以登入帳號權限為準。本研究主要使用自行保留的測試集進行模型評估，未取得 Kaggle 官方排名。官方 $R^2$ 與本地定義一致；本地額外報告 MAE、MSE、RMSE 與區間。

# 19B｜新版繳交與網站架構

依最新規定，主要繳交為 GitHub repository 與可瀏覽的 web；報告、對話與資訊圖表作為補充附件。分析核心仍是 Kaggle 資料、LinearRegression、Feature Selection、Evaluation、含預測區間的預測圖，以及 CRISP-DM 六階段。網站與本報告保留 NotebookLM 超過 100 字摘要及 GPT 輔助內容。

原始碼：https://github.com/maplenight0918/HW2-Multiple-Linear-regression

Pages 發布目標：https://maplenight0918.github.io/HW2-Multiple-Linear-regression/

| 功能 | 實作 |
| --- | --- |
| 兩題下拉選單 | Flood 20 欄／King County 19 欄；排除 ID 與 Target |
| 自訂 Dataset | 公開 CSV URL 或上傳，指定 Target 及輸入欄位 |
| 可解釋比較 | All／KBest／RFE／Lasso；主模型以訓練 CV 鎖定 |
| 預測與區間 | 五組互動圖表、實際新樣本預測、95% conformal |
| 研究與來源 | 六階段、NotebookLM 摘要、GPT 輔助、原始文獻連結 |

Pages 發布靜態前端與真實預先計算的 JSON。兩題互動圖、分析表與已訓練公式的單筆預測不需後端；自訂 CSV 的重新訓練由獨立 FastAPI 服務執行。前端不把示範輸出冒充新資料分析。未連接後端時會顯示設定提示。

網站係數圖顯示主要模型、以絕對值排序前 12 項，提示框顯示六位小數。Flood 各標準化係數相近是實際結果，並非同一數值重複顯示；不藉縮小座標範圍誇大差異。切換篩選比較不會偷偷更換已鎖定的主模型。

公開白名單包含網站、程式、Notebook、分析本文與研究來源；原始私人對話與完整本地 Git 歷史不發布。Pages 狀態：已推送並驗證 Pages。即時部署證據見 outputs/web/github_deployment.json。

# 19C｜第二題：King County 房價

資料來源：[S16] Kaggle House Sales in King County，harlfoxem/housesalesprediction，固定 version 1；https://www.kaggle.com/datasets/harlfoxem/housesalesprediction 。Kaggle metadata 標示 CC0。原始 CSV 21,613 列、21 欄；排除 id 與 price 後 19 個輸入，Target 為美元價格 price。

同一住宅可能重複交易，先按日期保留每個 id 最早一筆，共 21,436 間住宅，避免同屋跨集合。date 轉為自 1970 年的天數、zipcode 作類別；訓練折內補值、標準化及 OneHotEncoder，完整模型產生 87 個編碼後輸入。原始特徵數仍是 19。

| 項目 | 實際結果 |
| --- | --- |
| 訓練／校準／測試 | 12,861／4,287／4,288 |
| 主要模型／選模 | LinearRegression All；訓練內五折 CV |
| CV RMSE（美元） | 158,734.995411 |
| 測試 MAE（美元） | 94,710.113635 |
| 測試 RMSE（美元） | 153,909.108029 |
| 測試 $R^2$ | 0.828156 |
| 區間涵蓋率／平均寬度 | 94.9860%／USD 544,497.47 |

房價亦比較 All、SelectKBest、RFE、Lasso 篩選與 Ridge／Lasso 模型，測試結果僅作鎖定後診斷；詳見 outputs/web/housing_models.csv。此題與自訂 CSV 的 Lasso 篩選採固定 alpha=0.01，不能稱作 Flood 的 LassoCV。

sqft_living = sqft_above + sqft_basement 造成精確共線性，含截距設計矩陣秩為 87／88，故未強行報告名目欄數的 Adjusted $R^2$。日期隨機切分不代表未來市場驗證，係數亦不能當因果效果。95% split conformal 未截斷負下界，4,288 筆測試中 764 筆下界低於零；平均寬度較大且不保證昂貴住宅的條件涵蓋。

# 19D｜自訂 CSV 操作與驗證

選單切至自訂 CSV，可貼上公開 HTTPS CSV URL 或上傳檔案，再指定數值 Target 與輸入欄位。例如老師指定的 50 Startups：https://raw.githubusercontent.com/Avik-Jain/100-Days-Of-ML-Code/master/datasets/50_Startups.csv 。此範例不是另冒充符合 14～39 欄限制的主要 Kaggle 題目。

允許 50～5,000 筆、2～40 欄與最多 5 MB；Target 至少三種數值，排除 ID／index／*_id。重複資料刪除，無限值轉缺失並於訓練折內補值；類別與未知值按 Pipeline 處理。網址只接受公開網路位址，轉址亦重新驗證。資料只暫存記憶體，30 分鐘過期或重啟即移除。

一般採訓練／校準／測試 60／20／20%，小資料至少保留 19 筆校準以取得有限的 95% conformal 分位數。50 Startups 實際為 21／19／10 筆：主模型 LR_KBest_2、校準半寬 18,431.045365、平均寬度 36,862.090729，測試涵蓋 9／10。此例顯示名目 95% 不等於每個有限測試集都剛好 95%。

前處理、Target 標準化及篩選在五折各訓練部分擬合；依 CV 鎖定主要線性模型，校準只估計區間，測試只作評估。改動輸入特徵後舊結果會失效，需重新分析。

本機瀏覽器已實際操作兩題切換、五組互動圖、預測工具、CSV URL 分析、檔案上傳、非法網址與手機排版。遠端 Pages 和 API 必須分開驗證，不能從本機測試推論雲端已上線。使用方式與部署證據見 WEB_DEPLOYMENT.md、report/web_validation.md。

# 20 | Conclusion

本研究完成 Kaggle 真實下載資料的可重現回歸流程，Flood 20 與 King County 19 個原始輸入符合新版 >13、<40 條件。Feature Selection 的價值在於實證比較，不一定要刪除特徵：Flood 全部特徵的主要線性模型優於強制減維；LassoCV 的非零結果也支持保留完整訊號。

Flood 主模型 RMSE=0.020080、$R^2$=0.844878，進階比較模型改善約 7.57% RMSE。95% Conformal 區間的整體涵蓋率為 94.97%，但局部不足與殘差結構提醒我們：模型可作 benchmark 與教學，不能直接承擔真實洪災風險判斷。

King County 延伸到不同單位與類別輸入，說明同一分析流程如何應用到第二個題目；其精確共線性、負區間下界與較大誤差亦呈現線性模型的限制。兩題下拉與自訂資料輸入對應新增加分功能，是否計分由老師判定。

| 提交內容 | 說明 |
| --- | --- |
| 主要：GitHub 原始碼 | 使用者指定 repository；發布採乾淨公開匯出 |
| 主要：互動網站 | 已推送並驗證 Pages |
| NotebookLM／GPT 輔助 | 真實研究摘要與協助內容均已整合 |
| 選用：PDF／Notebook／對話 | 本地保留完整附件；對話範圍依匯出截止時間 |
| Kaggle 官方排名 | 未正式提交；以實際獨立測試評估 |

新版功能與實際驗證證據見 report/web_validation.md；詳細資料、模型、文件與打包檢查見 report/validation_report.md。遠端部署與額外服務的狀態另列，不以檔案存在推論服務已上線。

# 參考來源｜S01–S05

## S01 · Regression with a Flood Prediction Dataset

URL：https://www.kaggle.com/competitions/playground-series-s4e5

作者／組織：Walter Reade、Ashley Chow／Kaggle

日期：2024；查閱時頁面顯示競賽已結束，並有 Late Submission 入口。

主題：競賽背景、資料生成與評估。

## S02 · playground_series 公開資料集鏡像

URL：https://www.kaggle.com/datasets/johnwicknice/playground-series

作者／組織：wang tong（johnwicknice）／Kaggle

日期：2024-05-18；version 1。

主題：合法公開取得 CSV。

## S03 · Feature selection

URL：https://scikit-learn.org/stable/modules/feature_selection.html

作者／組織：scikit-learn developers

日期：持續更新，頁面未提供單一發表日。

主題：單變量選擇、RFE、模型係數選擇。

## S04 · Linear Models

URL：https://scikit-learn.org/stable/modules/linear_model.html

作者／組織：scikit-learn developers

日期：持續更新，未列單一發表日。

主題：OLS、Ridge、Lasso。

## S05 · Common pitfalls and recommended practices

URL：https://scikit-learn.org/stable/common_pitfalls.html

作者／組織：scikit-learn developers

日期：持續更新，未列單一發表日。

主題：前處理一致性與資料洩漏。

詳細發現、與作業的關係及授權界線見 research/sources.md。

# 參考來源｜S06–S10

## S06 · A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification

URL：https://arxiv.org/abs/2107.07511

作者：Anastasios N. Angelopoulos、Stephen Bates

日期：2021（arXiv 初版；來源頁含修訂日期）。

主題：Conformal prediction。

## S07 · het_breuschpagan

URL：https://www.statsmodels.org/stable/generated/statsmodels.stats.diagnostic.het_breuschpagan.html

作者／組織：statsmodels developers

日期：持續更新，未列單一發表日。

主題：殘差異質變異檢定。

## S08 · S4E5 competition solution discussion

URL：https://www.kaggle.com/competitions/playground-series-s4e5/discussion/500453

作者／組織：Kaggle 參賽者；可見內容連結 jamesking76 的 AutoML 解法，作者身分不額外推定。

日期：2024；精確發表日未確認。

主題：列內總和、標準差與集成方法。

## S09 · Awesome AutoGluon: Competition Solutions

URL：https://github.com/autogluon/autogluon/blob/master/AWESOME.md

作者／組織：AutoGluon maintainers

日期：持續更新；S4E5 條目標示 2024-05-31。

主題：公開競賽集成解法。

## S10 · Lasso model selection: AIC-BIC / cross-validation

URL：https://scikit-learn.org/stable/auto_examples/linear_model/plot_lasso_model_selection.html

作者／組織：scikit-learn developers

日期：持續更新，未列單一發表日。

主題：以驗證誤差呈現正則化選擇。

詳細發現、與作業的關係及授權界線見 research/sources.md。

# 參考來源｜S11–S15

### S11 • Linear Models（實驗版本核對）

URL：https://scikit-learn.org/1.6/modules/linear_model.html

作者／組織：scikit-learn developers

日期：版本 1.6.1 文件；查閱 2026-10-20。

主題：核對使用者研究整理的 OLS、Ridge、Lasso、分位數與求解器適用範圍。

### S12 • Feature selection（實驗版本核對）

URL：https://scikit-learn.org/1.6/modules/feature_selection.html

作者／組織：scikit-learn developers

日期：版本 1.6.1 文件；查閱 2026-10-20。

主題：KBest、RFE 與模型選擇。

### S13 • Common pitfalls（實驗版本核對）

URL：https://scikit-learn.org/1.6/common_pitfalls.html

作者／組織：scikit-learn developers

日期：版本 1.6.1 文件；查閱 2026-10-20。

主題：Pipeline、防洩漏與隨機性。

### S14 • scikit-learn 線性模型估計器與求解器技術選型指南

作者／組織：使用者提供，使用者說明為 NotebookLM 研究整理。

日期：2026-10-20 收件；實際研究日期未提供。

主題：研究摘要原始附件；13 頁。

本地檔案：research/notebooklm_chat.pdf。

### S15 • HW2 對話內容整理與實作提示詞存檔

作者／組織：使用者提供之 ChatGPT 整理稿。

日期：文件標示製作日期 2026-10-20。

主題：作業需求、特徵數限制、研究與實作提示詞；4 頁。

本地檔案：research/chatgpt_session.pdf。

詳細發現、與作業的關係及授權界線見 research/sources.md。

# 參考來源｜S16–S18

## S16 · 第二題：House Sales in King County, USA

URL：https://www.kaggle.com/datasets/harlfoxem/housesalesprediction

作者／組織：harlfoxem / Kaggle

日期：version 1，2016-08-25（Kaggle API metadata）

主題：房屋成交價多元回歸；19 個原始輸入特徵。

## S17 · Using custom workflows with GitHub Pages

URL：https://docs.github.com/en/pages/getting-started-with-github-pages/using-custom-workflows-with-github-pages

作者／組織：GitHub Docs。

日期：未提供固定出版日期；查核 2026-10-28。

主題：GitHub Actions 靜態網站建置與 Pages 發布。

## S18 · Deploy a FastAPI App

URL：https://render.com/docs/deploy-fastapi

作者／組織：Render。

日期：未提供固定出版日期；查核 2026-10-28。

主題：FastAPI Web Service 部署。

詳細發現、與作業的關係及授權界線見 research/sources.md。

# 附錄｜重現設定與檔案索引

Python：3.9.12 (main, Mar 29 2023, 09:45:36)

| 套件 | 實際版本 |
| --- | --- |
| numpy | 1.24.2 |
| pandas | 2.3.3 |
| scikit-learn | 1.6.1 |
| scipy | 1.13.1 |
| statsmodels | 0.14.6 |
| matplotlib | 3.9.4 |
| joblib | 1.5.3 |
| PyMuPDF | 1.26.5 |
| nbformat | 5.9.0 |
| nbclient | 0.8.0 |
| pytest | 8.4.2 |
| requests | 2.32.5 |

固定種子：42；CV 五折；KBest/RFE k=5,10,15；LassoCV 三折內層，12 個候選 alpha。精確 estimator 參數保存在 selection_lock.json 及 environment.json。完整來源碼在 src/，Notebook 直接呼叫同一套模組，不維護相互矛盾的實作。

執行：python -m src.run_experiment；測試：python -m pytest -q；重建報告：python scripts/build_report.py；驗收打包：python scripts/validate_and_package.py。先依 README 安裝 requirements.txt 並取得字型與資料。

原始資料雜湊（train.csv）：6c9adeacec0537306a80b957a69e57bf6d389e3c02c1ff33ca0a7dcb5a9b30fb

欄位、係數、OLS HC3、VIF、失敗案例與所有 CV fold 均有獨立 CSV。圖表以 PNG 保存，方便老師重看；PDF 不依賴 Notebook 才能閱讀。