HW2 • CRISP-DM • REGRESSION EXPLORER

從特徵選擇到可解釋的預測區間

Flood 與 King County 迴歸研究室

學號：7114056093 | 更新：2026-10-28

資料、程式、圖表與統計結果均由本次專案實際執行產生。

0.020080　主要模型測試 RMSE
0.844878　主要模型測試 R^2
94.97%　95% 預測區間實際涵蓋率

核心發現：20 個原始特徵共同提供訊號。強制刪減會損失預測能力；進階非線性模型雖然更準確，主要模型仍採 LinearRegression，以完成作業所需的解釋與統計分析。

GitHub＋互動網站
下拉切換兩個 Kaggle 題目、比較特徵選擇、解讀預測區間，並支援連接分析服務後輸入自訂 CSV。
本 PDF 是新版作業的補充分析附件。

摘要與閱讀導覽

本研究使用 Kaggle Playground Series S4E5 的公開合成資料鏡像，共 1,117,957 筆有標籤樣本與 20 個數值特徵，預測連續目標 FloodProbability。採固定種子切分訓練、校準及獨立測試資料，並在訓練內以五折交叉驗證比較 All Features、SelectKBest、RFE、LassoCV，以及 Ridge、Lasso 和梯度提升。主要 LinearRegression 測試 RMSE 為 0.020080、R^2 為 0.844878；LassoCV 未刪除任何特徵，刪減到 15 欄的線性模型 RMSE 約 0.0324。

Split conformal 以 178,873 筆獨立校準樣本建立 95% 個別預測區間，測試涵蓋率 94.97%，平均寬度 0.080116。殘差存在非正態與異質變異跡象，且分段涵蓋率不足，說明整體達標不能取代局部可靠性分析。

本報告依序呈現研究動機、資料來源、EDA、資料準備、特徵選擇、模型與評估、回歸假設、預測區間、文獻比較、NotebookLM 狀態、GPT 輔助內容、部署、結論、參考來源與附錄。所有測試比較均於模型設定鎖定後執行，不據此重選模型。

新版以 GitHub 與網站為主要繳交。本報告保留 Flood 完整統計研究，並補充 King County 房價分析、兩題互動網站與自訂 CSV 流程；PDF 與對話列為補充附件。原始輸入分別 20 與 19 欄，均符合 >13、<40，也符合較早的 10～20 欄條件。

關鍵詞：多元線性回歸、特徵選擇、資料洩漏、CRISP-DM、Split conformal。

01｜研究動機與 Business Understanding

預測 FloodProbability 的教育價值在於：把多個環境與基礎設施評分轉換成連續目標估計，練習比較變數貢獻、評估誤差並量化不確定性。可用於合成資料的情境比較、分析教學與模型流程驗證。資料缺少真實地理、時間與觀測事件的獨立驗證，因此不能直接用於疏散決策或真實洪災風險定價。

Multiple Linear Regression 提供明確的加法模型、係數與殘差，能建立透明基準，並檢查特徵選擇是否真的改善泛化。輸入是 20 個評分型數值特徵；輸出是資料集定義的 FloodProbability，不是二元洪災分類標籤。

成功標準：在不使用測試資料調參的前提下，最小化訓練內 CV RMSE，再以獨立測試集報告 MAE、MSE、RMSE 與 R^2；同時呈現 95% 區間的實際涵蓋率及寬度。並不事先假設所有特徵都必要，也不預設高複雜度模型一定更好。

CRISP-DM 階段	本研究產出
Business Understanding	研究目標、適用界線與成功標準
Data Understanding	真實 CSV 稽核、分布與相關性
Data Preparation	互斥資料切分、Pipeline、輸入驗證
Modeling	特徵選擇與五折 CV，鎖定主要模型
Evaluation	獨立測試、殘差與預測區間
Deployment	GitHub、網站、API、joblib 與 Notebook

02｜Dataset Description 與來源

原始競賽：[S01] Regression with a Flood Prediction Dataset，Kaggle Playground Series S4E5。官方競賽下載 API 回應 401，因此改用 Kaggle 公開鏡像 [S02] johnwicknice/playground-series 的 version 1。下載檔名、CSV 結構與預期競賽筆數吻合；保存 SHA-256，但沒有可供逐位元比對的官方檔案，因此不宣稱完成官方雜湊核對。

官方將 Playground 定義為合成資料練習。本專案沒有自行合成或改寫原始資料。原始生成模型的架構、參數及完整生成程式未取得，不能以欄名推定實際物理量或因果機制。鏡像 API 標示 Apache 2.0，更新時間 2024-05-18；鏡像標記不自動取代原競賽條款。rules 動態頁未完整可讀，正式提交或外部再發布前需確認原始規則。

項目	稽核結果
有標籤 train.csv	1,117,957 列 × 22 欄
官方 test.csv	745,305 列 × 21 欄
原始有效特徵	20（排除 id 與 Target）
Target	FloodProbability
缺失／無限值	0 / 0
重複輸入列	0
型別	20 個 int64；Target float64
輸入尺度	觀測範圍 0～19；未定義物理單位
目標範圍	0.285～0.725

無類別特徵，因此不建立類別編碼。ID 僅用於識別與 Kaggle 提交，不是模型輸入。官方 test.csv 沒有 Target，與本研究從 train.csv 保留的測試集不同。

03｜Data Understanding：目標與欄位

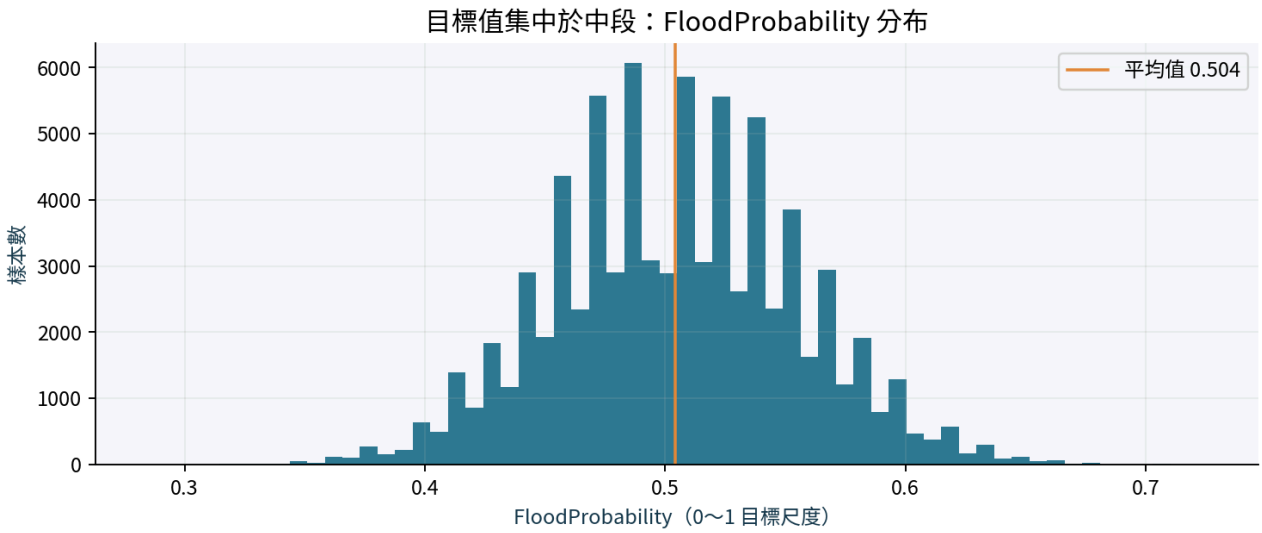


圖 1。訓練子樣本的目標分布。評分集中於中段，不代表現實世界的洪災盛行率。

全部 EDA 圖使用固定的訓練子樣本 80,000 筆；散點圖再抽樣 2,500 筆，以減少重疊。資料完整性稽核則讀取全部 CSV。描述統計見 descriptive_statistics.csv，包含 count、mean、std、min、四分位與 max。

代碼	原始欄名	代碼	原始欄名
F01	MonsoonIntensity	F11	IneffectiveDisasterPreparedness
F02	TopographyDrainage	F12	DrainageSystems
F03	RiverManagement	F13	CoastalVulnerability
F04	Deforestation	F14	Landslides
F05	Urbanization	F15	Watersheds
F06	ClimateChange	F16	DeterioratingInfrastructure
F07	DamsQuality	F17	PopulationScore
F08	Siltation	F18	WetlandLoss
F09	AgriculturalPractices	F19	InadequatePlanning
F10	Encroachments	F20	PoliticalFactors

04｜Data Understanding：特徵分布

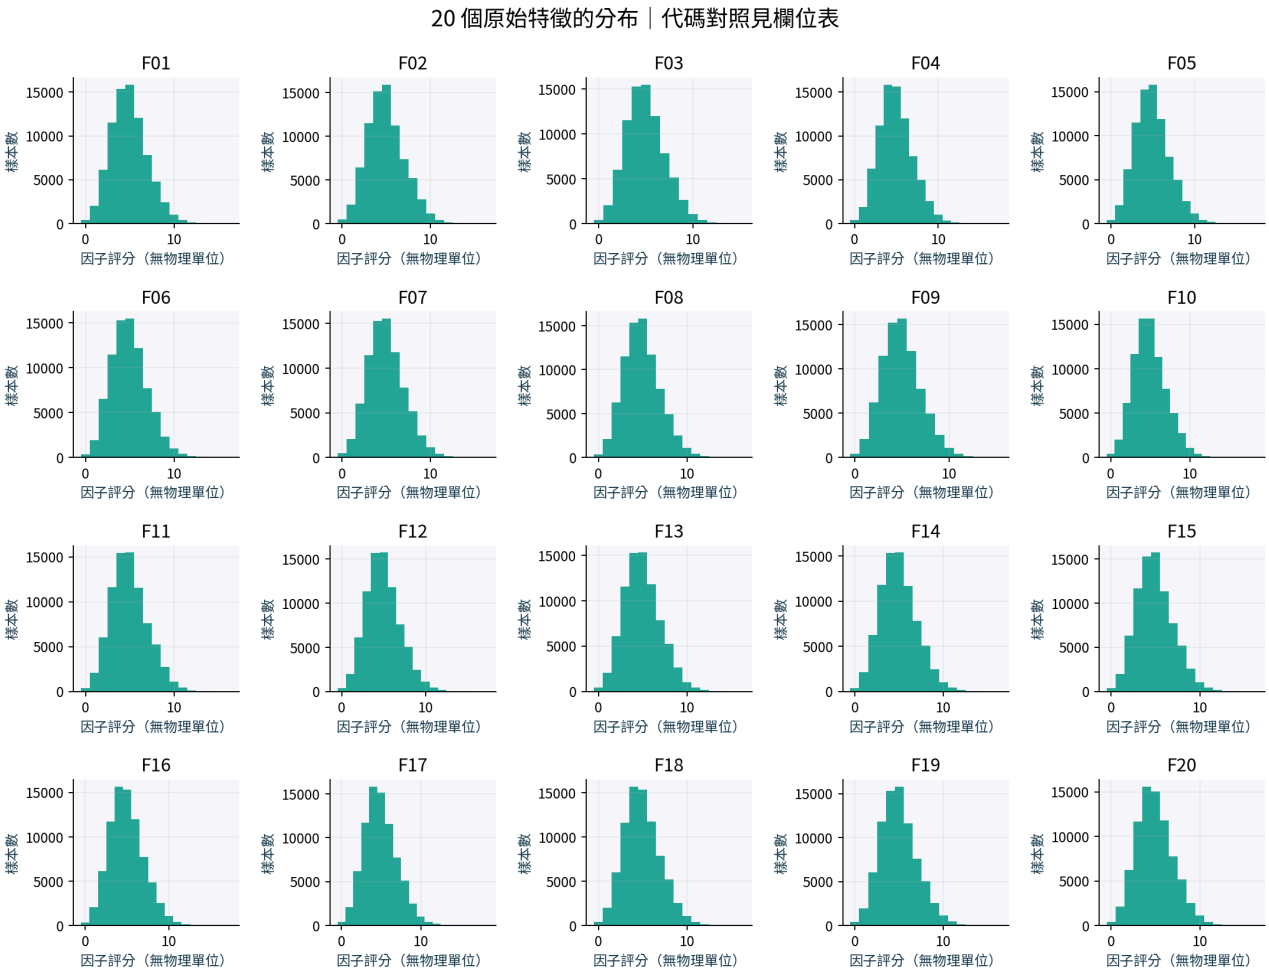


圖 2。20 個原始因子的直方圖；F01～F20 對照前頁。橫軸均為資料提供的評分，縱軸為樣本數。

特徵均為整數評分，分布存在離散性與尾端樣本。分布形狀不足以辨認資料的實際生成機制；未提供物理單位，因此不以雨量、面積或機率替代原始評分。

05｜Data Understanding：相關性與離群值

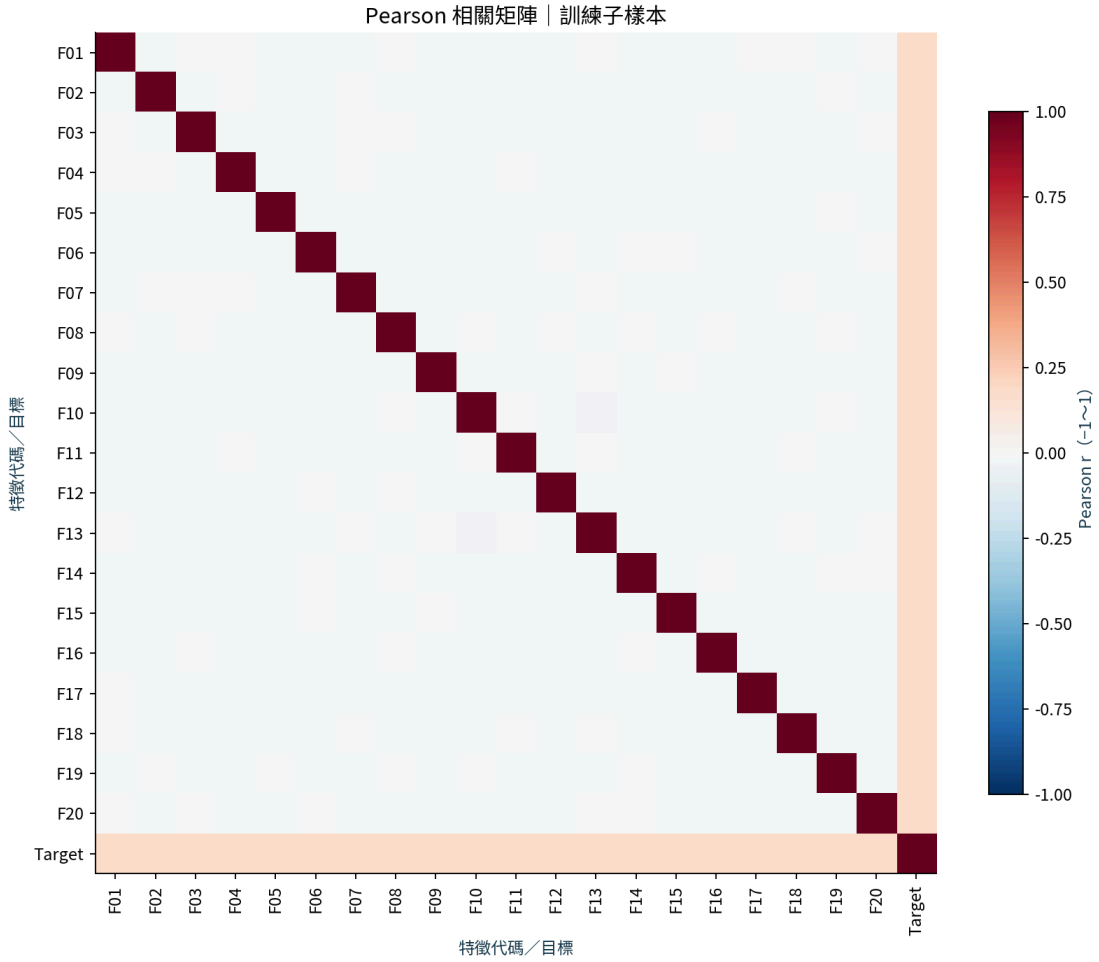


圖 3。Pearson 相關矩陣。特徵間相關很弱，但各特徵可共同累積預測訊號。

特徵間最大絕對相關為 0.0243，最大 VIF 為 1.0043，未見嚴重線性共線性。這支持「弱相關的多個特徵共同貢獻」的解讀，不能據此宣稱因果獨立。Pearson 檢查只反映線性關係，且不直接用全資料相關排序選擇模型。

06｜Data Understanding：趨勢與尾端

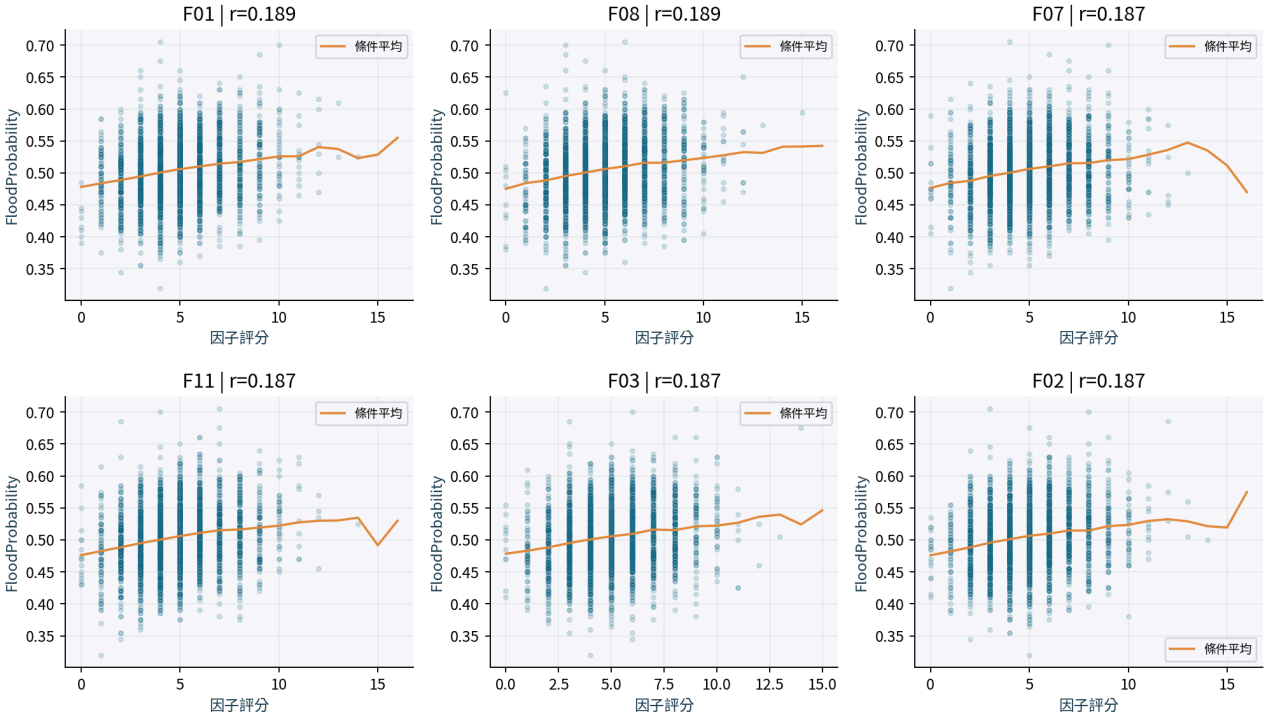


圖 4。訓練內與 Target 絕對相關最高的六個特徵；橘線為相同評分的平均 Target。尾端樣本較少，均值較不穩定。

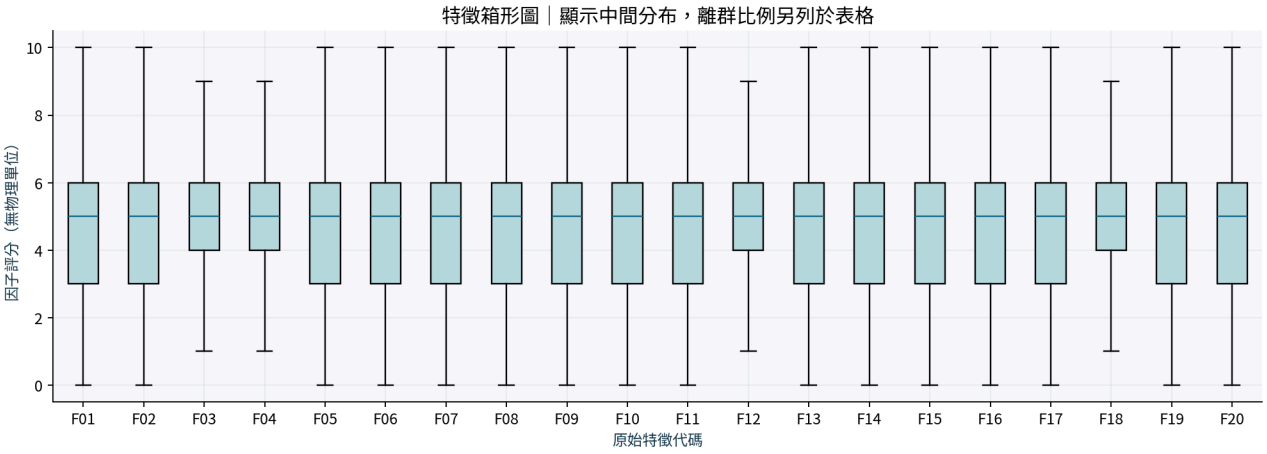


圖 5。箱形圖為易讀性隱藏離群點；離群比例依訓練 IQR 另存 outlier_analysis.csv。沒有以任意規則刪除尾端樣本。

IQR 外觀測不等於錯誤資料。未發現負值、無限值或非法型別，因此保留離群觀測，讓獨立測試反映完整分布；未利用測試誤差決定刪除規則。

07｜Data Preparation 與防洩漏設計

資料角色	筆數	用途
完整有標籤資料	1117957	僅資料稽核；提交專用模型可全量重訓
主要訓練部分	715492	最終候選模型擬合
獨立校準集	178873	只估計區間誤差分位數
本地獨立測試集	223592	模型鎖定後一次性診斷
CV 訓練內子樣本	80000	方法／參數選擇與 EDA
官方無標籤測試集	745305	只產生 submission.csv

採 random_state=42。先切分 80% development / 20% testing，再將 development 的 20% 留作 calibration，實際比例為約 64%／16%／20%。三組索引保存為 splits.npz，並檢查 ID、列索引及完全重複輸入的互斥性。CV 子樣本不超出真正訓練集合。

一般流程為 median imputer → StandardScaler → selector → model，每一 fold 都 clone 並重新 fit。資料沒有缺失，因此 imputer 是部署防護，不改變本次完整數值。標準化對純 OLS 的預測不構成必要條件，但利於 Ridge／Lasso 的懲罰與標準化係數比較。沒有類別資料，不強加編碼。

LassoCV 篩選流程特殊處理為 selector → imputer → scaler → LinearRegression。因本資料無缺失、原始特徵同屬評分尺度，LassoCV 直接在原始 X 進行三折內層選擇，避免把整個 outer fold 的 scaler 估計帶入 inner fold。若未來訓練資料有缺失或異質單位，須改用內層完整 Pipeline 搜尋，不能直接沿用此篩選流程。

先保存 selection_lock.json，才計算測試預測。校準集不參與任何 selector、scaler、超參數或模型選擇；測試集也不參與區間寬度設定。

08｜Feature Selection：設計與 CV

All Features 為 20 欄基準。SelectKBest 以 f_regression 衡量單變量線性關聯；RFE 以 LinearRegression 係數遞迴刪除、step=5。兩者各測試 5、10、15 欄。LassoCV 使用 12 個 alpha（10^{-5} 至 10 ^{2}），內層三折，依非零係數篩選後再做 OLS。[S03–S05]

候選模型	平均保留數	CV RMSE	折間 SD
LR_All	20	0.020181	0.000061
LR_KBest_5	5	0.046224	0.000222
LR_RFE_5	5	0.046287	0.000274
LR_KBest_10	10	0.040316	0.000145
LR_RFE_10	10	0.040378	0.000194
LR_KBest_15	15	0.032437	0.000126
LR_RFE_15	15	0.032349	0.000073
LR_LassoSelect	20	0.020181	0.000061
Ridge_0.1	20	0.020181	0.000061
Ridge_10	20	0.020181	0.000061
Ridge_1000	20	0.020201	0.000054
Lasso_1e-05	20	0.020181	0.000060
Lasso_0.0001	20	0.020187	0.000057
Lasso_0.001	20	0.020793	0.000060
HGB_Summary	20	0.018732	0.000061

共同外層設計：KFold(n_splits=5, shuffle=True, random_state=42)，樣本數 80,000。CV SD 為五折誤差的標準差，不是獨立樣本信賴區間。此表用於模型選擇，選定模型的 CV 估計可能偏樂觀；最終泛化由獨立測試集評估。

主要模型在 LinearRegression 家族中依 CV RMSE 最小值選擇。All 與 LassoSelect 產生相同結果時依固定候選順序保留 All。進階比較模型的整體 CV 更佳，但不取代作業主要線性模型。

09｜Feature Selection：結果與解釋

方法	數量	最終完整訓練部分選用欄位
LR_All	20	F01, F02, F03, F04, F05, F06, F07, F08, F09, F10, F11, F12, F13, F14, F15, F16, F17, F18, F19, F20
LR_KBest_15	15	F01, F02, F03, F04, F06, F07, F08, F09, F11, F14, F16, F17, F18, F19, F20
LR_RFE_15	15	F02, F03, F05, F07, F08, F10, F11, F12, F13, F14, F15, F17, F18, F19, F20
LR_LassoSelect	20	F01, F02, F03, F04, F05, F06, F07, F08, F09, F10, F11, F12, F13, F14, F15, F16, F17, F18, F19, F20

各 CV fold 的選中名稱與分數完整保存於 cv_folds.csv；本頁列出完整訓練部分擬合後的名稱代碼。訓練子樣本與完整訓練的排序可不同，因許多特徵的效果接近，不能把微小排序差距當成穩定的因果重要性。

LassoCV 最佳 alpha=1e-05，保留 20 欄，沒有任何係數壓成零。它不保證固定特徵數。最終保留 All 並非忽略 Feature Selection，而是實驗顯示刪減會損失累積訊號；最少 5 欄至 15 欄的方案都已實際比較。

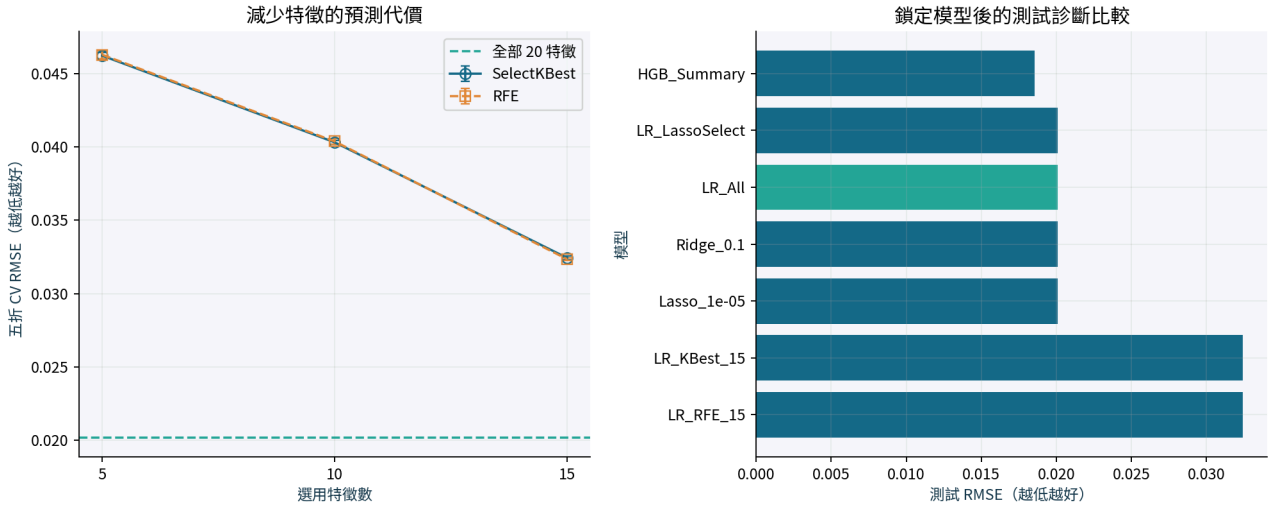


圖 6。左：特徵數與 CV RMSE，誤差棒為折間 SD。右：鎖定模型後的測試診斷，僅用於比較，不據此重選主模型。

10｜Modeling：模型與方程式

主要模型 $\hat{y} = \beta_0 + \Sigma_j \beta_j x_j$；使用 sklearn.linear_model.LinearRegression，含截距。Ridge 比較 alpha={0.1,10,1000}；Lasso 比較 alpha={10^{-5},10^{-4},10^{-3}}。Ridge 懲罰係數平方和，Lasso 懲罰絕對值和；不同 estimator 的損失正規化不同，alpha 數字不能直接相互比較。[S04]

進階模型為 HistGradientBoostingRegressor，加入每筆輸入的 sum 與 std，原始輸入 20 欄、模型內部 22 欄。固定 max_iter=140、max_leaf_nodes=15、learning_rate=0.08、l2_regularization=10、early_stopping=False。只作單一合理設定比較，未宣稱充分調參或達到最佳可能分數。其衍生特徵不含 Target，也不估計跨樣本參數。

主要模型使用 715,492 筆擬合，截距（原始尺度）為 -0.05294076。例如 MonsoonIntensity 增加 1 評分、其他欄位固定時，預測增加約 0.005613；這是模型內條件關聯，不是因果效應。

特徵代碼	原始係數	標準化係數
F01	0.005613	0.011557
F02	0.005638	0.011807
F03	0.005663	0.011739
F04	0.005674	0.011636
F05	0.005658	0.011770
F06	0.005653	0.011623
F07	0.005649	0.011769
F08	0.005635	0.011650
F09	0.005629	0.011633
F10	0.005642	0.011759
F11	0.005643	0.011721
F12	0.005633	0.011677
F13	0.005662	0.011826
F14	0.005643	0.011721
F15	0.005638	0.011734
F16	0.005608	0.011577
F17	0.005678	0.011782
F18	0.005635	0.011654
F19	0.005613	0.011679
F20	0.005644	0.011798

完整數值見 coefficients.csv。標準化係數表示特徵增加一個訓練標準差的目標變化；不直接以原始係數排序重要性。

係數視覺化與推論界線

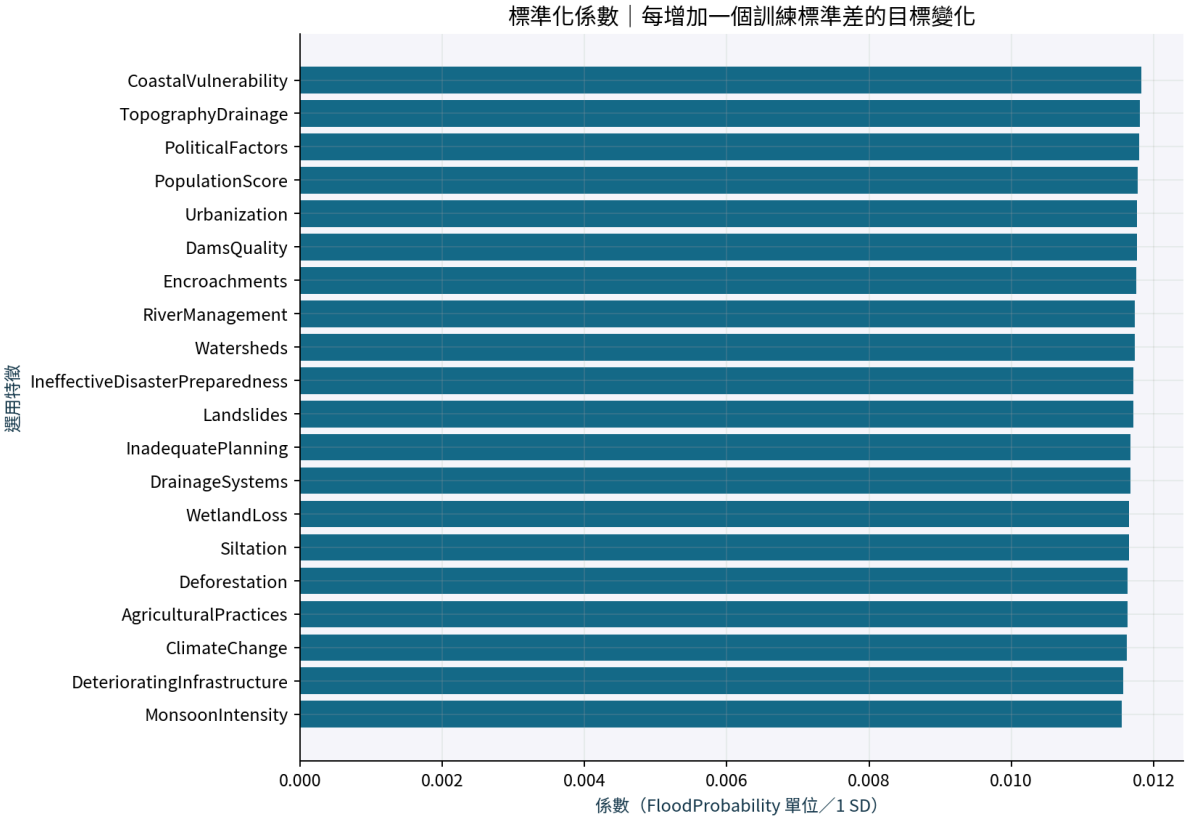


圖 6a。係數依標準化效果排列，數值接近；圖上的微小差距不能視為實質重要性或因果證據。

每個係數皆是在其他欄位固定時的條件關聯。合成資料的命名不提供因果識別；例如係數為正，不代表對該項設施進行真實介入就會增加洪災。估計誤差、資料生成過程及遺漏變數均會限制推論。

ols_hc3_inference.csv 另列訓練子樣本 OLS 的 robust 標準誤與區間。主模型在更大的訓練部分擬合，兩者用途不同；不把子樣本推論表誤標成完整主模型的參數區間。

11｜Evaluation：指標與模型比較

設殘差 $e_i=y_i-\hat{y}_i$、n 為本地測試樣本數：$MAE=\Sigma|e_i|/n$；$MSE=\Sigma e_i^2/n$；$RMSE=\sqrt{MSE}$；$R^2=1-\Sigma e_i^2/\Sigma(y_i-\bar{y})^2$。MAE／RMSE 的單位與 Target 相同；MSE 為平方單位；R^2 無單位且可能小於零。

Adjusted $R^2=1-(1-R^2)(n-1)/(n-p-1)$，本地測試 n=223,592、主要 OLS p=20，結果為 0.844864。僅在線性模型 n>p+1 時提供此代入值；測試集上的 adjusted R^2 是描述性指標，並不恢復選模後的無偏性。Ridge／Lasso／HGB 的有效自由度未估計，因此不套用名目欄數強行計算。

模型	原始欄數	MAE	MSE	RMSE	R^2
LR_All	20	0.015795	0.000403	0.020080	0.844878
LR_KBest_15	15	0.026089	0.001051	0.032414	0.595791
LR_RFE_15	15	0.026111	0.001051	0.032425	0.595506
LR_LassoSelect	20	0.015795	0.000403	0.020080	0.844878
Ridge_0.1	20	0.015795	0.000403	0.020080	0.844878
Lasso_1e-05	20	0.015798	0.000403	0.020080	0.844876
HGB_Summary	20	0.014497	0.000344	0.018559	0.867484

以上全部為實際測試結果，各方法代表方案先由 CV 決定。多組測試值屬事後診斷，沒有依此再搜尋或選擇最終方案。Ridge 與 OLS 幾乎一致，不應把小數尾端差異描述為實質改善。

進階 HGB + summary 的 RMSE 為 0.018559，比主模型降低 7.57%；這是本次固定設定與獨立切分的結果，不代表所有分布或真實災害情境下同樣優越。

12｜Evaluation：預測與失敗案例

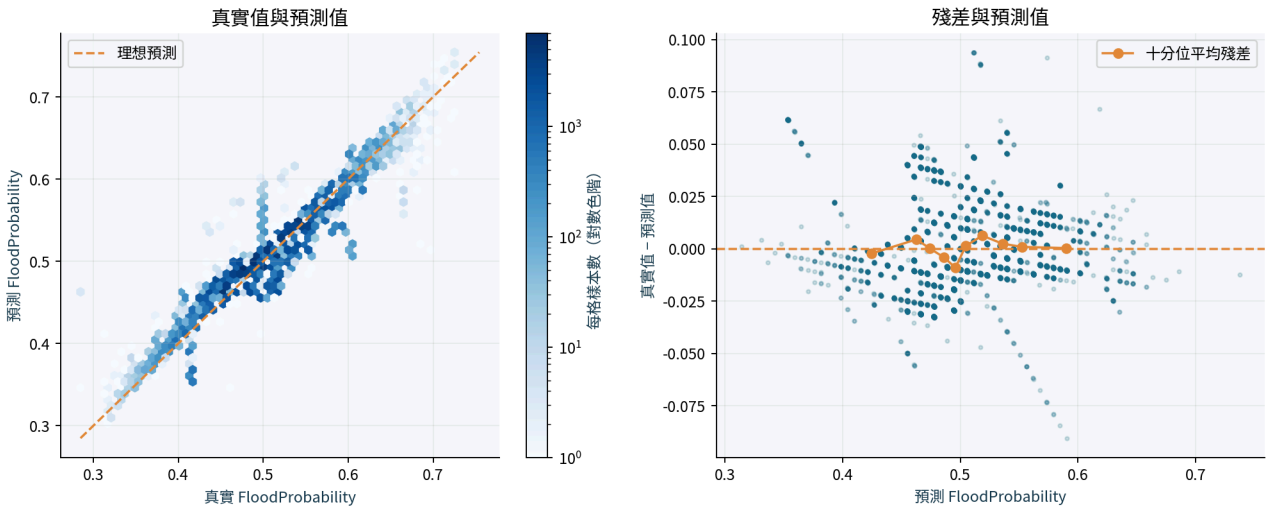


圖 7。左為完整測試集 hexbin 密度，避免重疊遮蔽。右以固定抽樣呈現殘差，橘線顯示十分位平均誤差。

理想預測落在對角線附近，但殘差圖呈現結構性起伏，表示簡單加法模型仍未充分捕捉合成資料的非線性。此為診斷結果，未據以回頭調整本次主模型。

樣本 ID	真實值	預測	絕對誤差
242964	0.285000	0.466375	0.181375
331323	0.285000	0.466138	0.181138
620002	0.695000	0.516872	0.178128
679010	0.285000	0.460659	0.175659
593506	0.285000	0.460565	0.175565

表中為鎖定模型後誤差最大的五筆，非資料清理依據。完整十五筆見 failure_cases.csv；不因它們偏離模型就刪除。下一輪研究可另設新驗證資料，探索非線性、異質誤差與資料生成規律。

13 | Regression Assumption Analysis

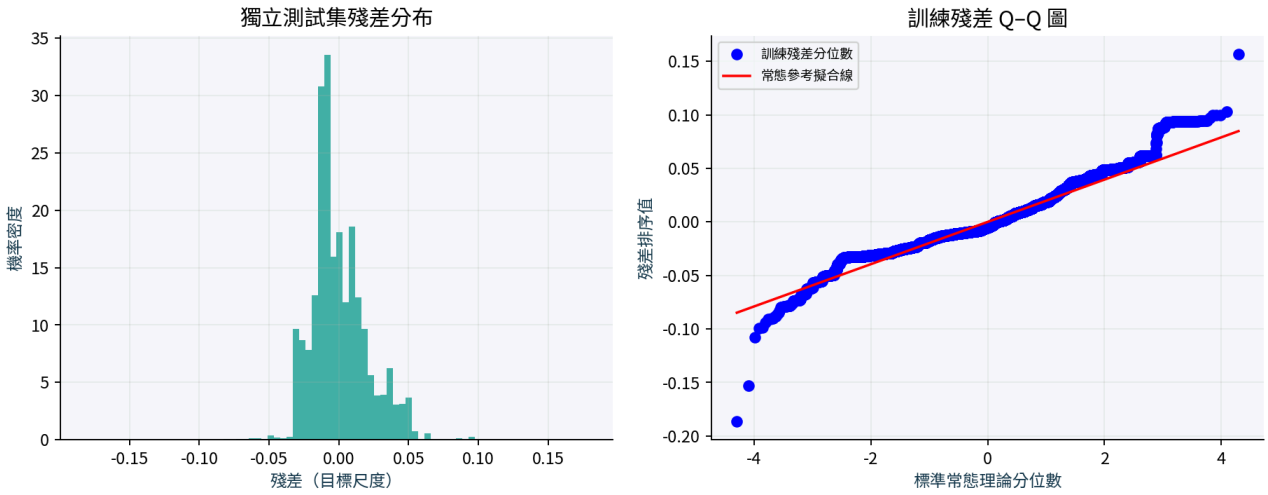


圖 8。測試殘差分布與訓練殘差 Q–Q 圖。尾部及偏斜偏離常態；大樣本下應同時看圖與效果量。

檢查	數據／判讀
Linearity	殘差分段平均有系統性波動，線性近似不完全充分
Independence	DW=2.0027；無自然時間順序，不能證明獨立
Homoscedasticity	BP LM=3464.68，p 極小；拒絕同質變異
Normality	JB=10280.3，偏度=0.705，峰度=4.047
Multicollinearity	最大 VIF=1.0043，未見嚴重共線性

BP／JB 在浮點輸出中 p=0 是數值下溢，不代表真正機率精確為零。80,000 筆使檢定對微小偏差敏感，但圖形也顯示實質結構。DW 使用隨機排列的截面資料，只是描述，沒有時序解釋。交換性／獨立性無法單靠殘差檢定證明。

異質變異使傳統同質 OLS 標準誤失準；本研究另提供 HC3 robust 係數標準誤及 95% 區間。HC3 不修正函數形式錯誤、未觀測混淆或選模後推論。該表只針對訓練子樣本、條件於已選特徵的探索性推論，不等於主要模型全量係數的正式確認性檢定。

14｜Prediction Interval：方法與結果

採 split conformal prediction [S06]。先固定模型，再用 calibration residual $s_i=|y_i-f(x_i)|$；令 m 為校準樣本數，$k=\text{ceil}((m+1)\times 0.95)$，取第 k 個排序誤差 q。新樣本的個別預測區間為 $[f(x)-q, f(x)+q]$。這是包含個別新觀測值的 Prediction Interval，不是條件平均值的 Confidence Interval。

項目	結果
Nominal coverage	95%
校準筆數 m	178873
有限樣本排序 k	169931
半寬 q	0.04005815
Empirical test coverage	94.9667%
Average interval width	0.08011631
點預測超出 0～1	0
下界／上界超出 0～1	0 / 0

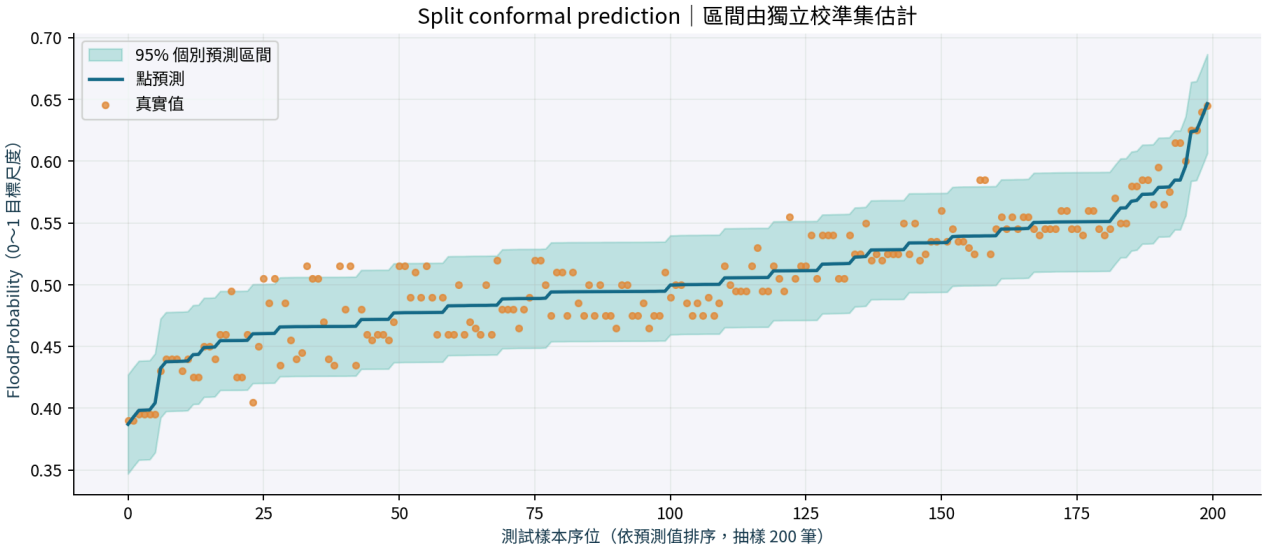


圖 9。從測試集固定抽樣 200 筆，再依預測值排序，同步排列真實值與上下界。固定半寬來自校準誤差分位數，不是任意 ±5%。

未裁切點預測或上下界，本次都落在 0～1。線性模型仍可能在新輸入上超出目標範圍；任意裁切會改變預測與區間的解讀。交換性與校準／測試分布一致時提供邊際涵蓋保證，不要求常態與等變異；分布轉移、相依樣本或局部風險子群則不保證。

15｜Prediction Interval：局部不足與限制

依預測值分組	筆數	RMSE	區間涵蓋率
(0.302, 0.455]	22360	0.021776	0.882513
(0.455, 0.466]	22359	0.028161	0.845879
(0.466, 0.478]	22359	0.025991	0.952234
(0.478, 0.494]	22359	0.018193	0.998614
(0.494, 0.5]	22359	0.018320	0.999821
(0.5, 0.511]	22359	0.017897	0.970482
(0.511, 0.528]	22359	0.020912	0.939443
(0.528, 0.54]	22359	0.016416	0.947225
(0.54, 0.568]	22359	0.013604	0.970437
(0.568, 0.754]	22360	0.014509	0.990027

整體涵蓋率為 94.97%，但十分位分組最低只有 84.59%。整體接近 95% 並不意味每個預測區段都可靠。

此分組僅為事後診斷，沒有用測試集重新調整區間。固定絕對殘差區間在低誤差區段偏寬，在高誤差區段可能不足。若要改善，可在全新實驗中使用局部尺度化 conformal 或 conformalized quantile regression，並另行保留校準／測試資料；不能直接根據本表擴張區間再稱為未見資料評估。

本次主要限制包括：合成資料的外部效度、沒有時間與地區資訊、內部 CV 只用固定 80,000 筆、有限 alpha 搜尋、未對超參數選擇作完整 nested-CV 效能估計，以及線性模型無法保證輸出有界。獨立測試提供主要泛化估計，但不替代真實地區或時間外驗證。

16 | Comparison with Existing Approaches

方法	優點	限制	本研究比較
Linear Regression	係數清楚、容易重現	函數形式與有界性受限	主要 RMSE 0.020080
Ridge	L2 可穩定相關變數	不會直接刪欄	與 OLS 幾乎相同
Lasso／LassoCV	L1 可稀疏化	選擇依 alpha 與尺度而變	選中 alpha 未刪任何欄
HGB + summary	捕捉非線性與整體訊號	解釋與運算成本較高	實測 RMSE 0.018559
AutoGluon／集成	整合多模型、適合競賽探索	資源與調參成本較高	僅文獻比較，沒有實作或自稱排名

上述優缺點為 [S03–S06] 的理論與本實驗的綜合解讀；S4E5 參賽者 [S08] 分享列內總和／標準差特徵，本研究因此預先設計 HGB 比較。AutoGluon 維護者 [S09] 列出該競賽的成功案例，只證明該類解法值得研究，不是本作業的實測表現。

視覺呈現參考 scikit-learn 範例 [S10] 的方法比較原則：統一座標、明示誤差與清楚圖例。本報告全部數值圖均由本次執行結果自行產生；沒有移用別人的圖形數據或排行榜截圖。

17｜NotebookLM 摘要

PASS：研究附件、摘要與來源已確認
使用者提供 13 頁研究整理，並確認匯入原 sources.md 的 S01–S10 網址。

使用者提供的 NotebookLM 研究整理指出，線性模型應依資料維度、共線性、離群值與計算資源選用。OLS 最小化殘差平方和，便於解釋各輸入與連續目標的關聯；Ridge 加入 L2 懲罰以縮減係數，Lasso 加入 L1 懲罰，可能產生零係數，因此可作特徵篩選。特徵選擇方面，SelectKBest 依單變量分數排序，RFE 反覆擬合並剔除較弱特徵，Lasso 則依正則化強度決定稀疏程度，不能保證固定保留數量。研究亦強調，補值、標準化與特徵選擇必須封裝於 Pipeline，並只在每個交叉驗證訓練折擬合；測試資料僅套用既有轉換，以避免資料洩漏。分位數回歸可估計不同條件分位數，值得作為異質變異資料之區間方法比較，但其實際涵蓋率仍須另外驗證。以上整理對應所提供 PDF 第 2–4、9–13 頁，概念經官方文件 [S11–S13] 核對；使用者已確認研究使用原來源清單 S01–S10；本文引用編號為整合時後補，並非原 PDF 的逐句引用標記。

摘要依使用者提供的 NotebookLM 研究文件 [S14] 整理，並由 AI Coding Agent 核對技術內容；不是逐字原始回答。原 PDF 完整保留於 research/notebooklm_chat.pdf。來源對應為後補核對，不冒稱原生引用標記。

收件與來源確認：2026-10-20。實際操作日期與 notebook 連結未提供，保持空白；不把收件日期當成研究日期。來源核對紀錄見 research/document_integration_review.md。

17B｜研究核對與本作業的連結

研究重點	來源對應	本作業如何使用
OLS／Ridge／Lasso	原 S04；核對 S11	比較相同切分與尺度下的模型
KBest／RFE／L1 選擇	原 S03；核對 S12	5／10／15／All 經 CV 比較
Pipeline／防洩漏	原 S05；核對 S13	各 fold 獨立 fit；測試只 transform
分位數與區間	原 S04；延伸 S06	主要實作獨立校準的 split conformal

與實驗的關係：LassoCV 保留 20 欄，顯示 L1 不保證刪除特徵。刪減至 15 欄的 KBest／RFE RMSE 約 0.0324，高於全部欄位 OLS 的 0.020080；Ridge／Lasso 改善有限。HGB 的 0.018559 是本專案實測比較，不是 NotebookLM 或他人排行榜分數。

技術修正：原文件討論的 SGDClassifier 與 LogisticRegression 求解器屬分類脈絡，不能直接當作 FloodProbability 回歸模型；newton-cholesky 不是本次 LinearRegression 的參數。OLS 求解本身不要求常態誤差；常態性涉及特定推論方法。分位數區間亦不能未驗證便宣稱 95% 涵蓋。

流程修正：原文件有全資料先標準化的示範，不能直接拿來評估內層 CV。本專案沿用已驗證的 fold-local 流程。固定種子只在相同資料與環境下支持重現，不承諾跨套件版本逐位元一致。

> 研究附件提供方法脈絡；實驗表格提供本作業證據。兩者分開標示。未採用原文無條件的「最快」「必須」「首選」斷言；分類 accuracy 範例不當作本次回歸評分。

18｜GPT 輔助內容

使用者已提供 research/chatgpt_raw_session.pdf，為瀏覽器匯出的 40 頁原始 ChatGPT 對話，從作業規定與題目選擇，到完整實作提示詞與匯出說明。舊的 4 頁整理稿 [S15] 仍保留作輔助文件，不再充當原始對話證據。

本次 AI Coding Agent 實際協助：資料與文獻查找、Python 專案、CSV 稽核、切分與 Pipeline、Feature Selection、模型、統計檢定、Conformal、圖表、部署、測試、Notebook、PDF、圖表檢閱、學號與研究文件整合，以及本輪公開對話的逐字匯出。所有實驗數值來自實際執行。

> 完整 GPT 對話：PASS：原始對話已合併（截至匯出時間）
> 附錄含 ChatGPT 原始 PDF 與本輪 Codex 公開訊息；獨立合併檔為 report/gpt_conversation.pdf。

本輪 Codex 擷取 43 則使用者與助理公開訊息，截止 2026-10-20T07:12:46.685Z（UTC）。原文以 JSON 保存，逐則 SHA-256 與 PDF 抽取文字核對；ChatGPT 原頁保留並以文字及像素核對。

匯出範圍是使用者提供的前續對話與本次 HW2 的公開文字，包含進度回覆；不含系統指令、內部推理與工具原始輸出。歷史訊息的舊狀態按原文保留，不用事後結論改寫。截止之後的新訊息可再追加；完整性證據見 conversation_export.json。

來源與原文不等於所有歷史建議都正確。最終方法與數據以本報告及實際驗收結果為準；作者仍須理解方法並對提交內容負責。

19｜Deployment 與 Kaggle 提交

predict_new_data(input_data) 接受 DataFrame、單筆字典或 CSV 路徑；檢查必要欄位、重複欄名、數值型別與無限值。多餘欄位如 id 被忽略。缺失值以已擬合訓練中位數補值並提出警示；超過訓練觀測範圍則提醒外推。函式返回 prediction、lower_95、upper_95。

```
from src.prediction import predict_new_data
result = predict_new_data("data/processed/new_samples.csv")
print(result)
```

prediction	lower_95	upper_95
0.573548	0.533490	0.613606
0.455261	0.415203	0.495320
0.454875	0.414817	0.494933
0.466213	0.426155	0.506271
0.466140	0.426081	0.506198

主要模型檔 outputs/models/primary_bundle.joblib 包含完整 Pipeline、原始欄位、訓練範圍與 conformal q。模型載入後預測與原模型一致；只載入本專案可信來源的 joblib 檔。

另以全部有標籤資料重訓相同鎖定方法，存成 submission_pipeline.joblib 並預測官方 745,305 筆資料。此模型不能宣稱保有原本獨立測試評分，也不能沿用原校準區間。submission.csv 格式為 id,FloodProbability，已與官方範例逐列核對 ID。

官方競賽已結束，查閱時頁面仍顯示 Late Submission。是否可晚交以登入帳號權限為準。本研究主要使用自行保留的測試集進行模型評估，未取得 Kaggle 官方排名。官方 R^2 與本地定義一致；本地額外報告 MAE、MSE、RMSE 與區間。

19B｜新版繳交與網站架構

依最新規定，主要繳交為 GitHub repository 與可瀏覽的 web；報告、對話與資訊圖表作為補充附件。分析核心仍是 Kaggle 資料、LinearRegression、Feature Selection、Evaluation、含預測區間的預測圖，以及 CRISP-DM 六階段。網站與本報告保留 NotebookLM 超過 100 字摘要及 GPT 輔助內容。

原始碼：https://github.com/maplenight0918/HW2-Multiple-Linear-regression

Pages 發布目標：https://maplenight0918.github.io/HW2-Multiple-Linear-regression/

功能	實作
兩題下拉選單	Flood 20 欄／King County 19 欄；排除 ID 與 Target
自訂 Dataset	公開 CSV URL 或上傳，指定 Target 及輸入欄位
可解釋比較	All／KBest／RFE／Lasso；主模型以訓練 CV 鎖定
預測與區間	五組互動圖表、實際新樣本預測、95% conformal
研究與來源	六階段、NotebookLM 摘要、GPT 輔助、原始文獻連結

Pages 發布靜態前端與真實預先計算的 JSON。兩題互動圖、分析表與已訓練公式的單筆預測不需後端；自訂 CSV 的重新訓練由獨立 FastAPI 服務執行。前端不把示範輸出冒充新資料分析。未連接後端時會顯示設定提示。

網站係數圖顯示主要模型、以絕對值排序前 12 項，提示框顯示六位小數。Flood 各標準化係數相近是實際結果，並非同一數值重複顯示；不藉縮小座標範圍誇大差異。切換篩選比較不會偷偷更換已鎖定的主模型。

公開白名單包含網站、程式、Notebook、分析本文與研究來源；原始私人對話與完整本地 Git 歷史不發布。Pages 狀態：發布設定已完成；遠端上線尚未驗證。即時部署證據見 outputs/web/github_deployment.json。

19C｜第二題：King County 房價

資料來源：[S16] Kaggle House Sales in King County，harlfoxem/housesalesprediction，固定 version 1；https://www.kaggle.com/datasets/harlfoxem/housesalesprediction 。Kaggle metadata 標示 CC0。原始 CSV 21,613 列、21 欄；排除 id 與 price 後 19 個輸入，Target 為美元價格 price。

同一住宅可能重複交易，先按日期保留每個 id 最早一筆，共 21,436 間住宅，避免同屋跨集合。date 轉為自 1970 年的天數、zipcode 作類別；訓練折內補值、標準化及 OneHotEncoder，完整模型產生 87 個編碼後輸入。原始特徵數仍是 19。

項目	實際結果
訓練／校準／測試	12,861／4,287／4,288
主要模型／選模	LinearRegression All；訓練內五折 CV
CV RMSE（美元）	158,734.995411
測試 MAE（美元）	94,710.113635
測試 RMSE（美元）	153,909.108029
測試 R^2	0.828156
區間涵蓋率／平均寬度	94.9860%／USD 544,497.47

房價亦比較 All、SelectKBest、RFE、Lasso 篩選與 Ridge／Lasso 模型，測試結果僅作鎖定後診斷；詳見 outputs/web/housing_models.csv。此題與自訂 CSV 的 Lasso 篩選採固定 alpha=0.01，不能稱作 Flood 的 LassoCV。

sqft_living = sqft_above + sqft_basement 造成精確共線性，含截距設計矩陣秩為 87／88，故未強行報告名目欄數的 Adjusted R^2。日期隨機切分不代表未來市場驗證，係數亦不能當因果效果。95% split conformal 未截斷負下界，4,288 筆測試中 764 筆下界低於零；平均寬度較大且不保證昂貴住宅的條件涵蓋。

19D｜自訂 CSV 操作與驗證

選單切至自訂 CSV，可貼上公開 HTTPS CSV URL 或上傳檔案，再指定數值 Target 與輸入欄位。例如老師指定的 50 Startups：https://raw.githubusercontent.com/Avik-Jain/100-Days-Of-ML-Code/master/datasets/50_Startups.csv 。此範例不是另冒充符合 14～39 欄限制的主要 Kaggle 題目。

允許 50～5,000 筆、2～40 欄與最多 5 MB；Target 至少三種數值，排除 ID／index／*_id。重複資料刪除，無限值轉缺失並於訓練折內補值；類別與未知值按 Pipeline 處理。網址只接受公開網路位址，轉址亦重新驗證。資料只暫存記憶體，30 分鐘過期或重啟即移除。

一般採訓練／校準／測試 60／20／20%，小資料至少保留 19 筆校準以取得有限的 95% conformal 分位數。50 Startups 實際為 21／19／10 筆：主模型 LR_KBest_2、校準半寬 18,431.045365、平均寬度 36,862.090729，測試涵蓋 9／10。此例顯示名目 95% 不等於每個有限測試集都剛好 95%。

前處理、Target 標準化及篩選在五折各訓練部分擬合；依 CV 鎖定主要線性模型，校準只估計區間，測試只作評估。改動輸入特徵後舊結果會失效，需重新分析。

本機瀏覽器已實際操作兩題切換、五組互動圖、預測工具、CSV URL 分析、檔案上傳、非法網址與手機排版。遠端 Pages 和 API 必須分開驗證，不能從本機測試推論雲端已上線。使用方式與部署證據見 WEB_DEPLOYMENT.md、report/web_validation.md。

20 | Conclusion

本研究完成 Kaggle 真實下載資料的可重現回歸流程，Flood 20 與 King County 19 個原始輸入符合新版 >13、<40 條件。Feature Selection 的價值在於實證比較，不一定要刪除特徵：Flood 全部特徵的主要線性模型優於強制減維；LassoCV 的非零結果也支持保留完整訊號。

Flood 主模型 RMSE=0.020080、R^2=0.844878，進階比較模型改善約 7.57% RMSE。95% Conformal 區間的整體涵蓋率為 94.97%，但局部不足與殘差結構提醒我們：模型可作 benchmark 與教學，不能直接承擔真實洪災風險判斷。

King County 延伸到不同單位與類別輸入，說明同一分析流程如何應用到第二個題目；其精確共線性、負區間下界與較大誤差亦呈現線性模型的限制。兩題下拉與自訂資料輸入對應新增加分功能，是否計分由老師判定。

提交內容	說明
主要：GitHub 原始碼	使用者指定 repository；發布採乾淨公開匯出
主要：互動網站	發布設定已完成；遠端上線尚未驗證
NotebookLM／GPT 輔助	真實研究摘要與協助內容均已整合
選用：PDF／Notebook／對話	本地保留完整附件；對話範圍依匯出截止時間
Kaggle 官方排名	未正式提交；以實際獨立測試評估

新版功能與實際驗證證據見 report/web_validation.md；詳細資料、模型、文件與打包檢查見 report/validation_report.md。遠端部署與額外服務的狀態另列，不以檔案存在推論服務已上線。

參考來源｜S01–S05

S01 · Regression with a Flood Prediction Dataset

URL：https://www.kaggle.com/competitions/playground-series-s4e5

作者／組織：Walter Reade、Ashley Chow／Kaggle

日期：2024；查閱時頁面顯示競賽已結束，並有 Late Submission 入口。

主題：競賽背景、資料生成與評估。

S02 · playground_series 公開資料集鏡像

URL：https://www.kaggle.com/datasets/johnwicknice/playground-series

作者／組織：wang tong（johnwicknice）／Kaggle

日期：2024-05-18；version 1。

主題：合法公開取得 CSV。

S03 · Feature selection

URL：https://scikit-learn.org/stable/modules/feature_selection.html

作者／組織：scikit-learn developers

日期：持續更新，頁面未提供單一發表日。

主題：單變量選擇、RFE、模型係數選擇。

S04 · Linear Models

URL：https://scikit-learn.org/stable/modules/linear_model.html

作者／組織：scikit-learn developers

日期：持續更新，未列單一發表日。

主題：OLS、Ridge、Lasso。

S05 · Common pitfalls and recommended practices

URL：https://scikit-learn.org/stable/common_pitfalls.html

作者／組織：scikit-learn developers

日期：持續更新，未列單一發表日。

主題：前處理一致性與資料洩漏。

詳細發現、與作業的關係及授權界線見 research/sources.md。

參考來源｜S06–S10

S06 · A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification

URL：https://arxiv.org/abs/2107.07511

作者：Anastasios N. Angelopoulos、Stephen Bates

日期：2021（arXiv 初版；來源頁含修訂日期）。

主題：Conformal prediction。

S07 · het_breuschpagan

URL：https://www.statsmodels.org/stable/generated/statsmodels.stats.diagnostic.het_breuschpagan.html

作者／組織：statsmodels developers

日期：持續更新，未列單一發表日。

主題：殘差異質變異檢定。

S08 · S4E5 competition solution discussion

URL：https://www.kaggle.com/competitions/playground-series-s4e5/discussion/500453

作者／組織：Kaggle 參賽者；可見內容連結 jamesking76 的 AutoML 解法，作者身分不額外推定。

日期：2024；精確發表日未確認。

主題：列內總和、標準差與集成方法。

S09 · Awesome AutoGluon: Competition Solutions

URL：https://github.com/autogluon/autogluon/blob/master/AWESOME.md

作者／組織：AutoGluon maintainers

日期：持續更新；S4E5 條目標示 2024-05-31。

主題：公開競賽集成解法。

S10 · Lasso model selection: AIC-BIC / cross-validation

URL：https://scikit-learn.org/stable/auto_examples/linear_model/plot_lasso_model_selection.html

作者／組織：scikit-learn developers

日期：持續更新，未列單一發表日。

主題：以驗證誤差呈現正則化選擇。

詳細發現、與作業的關係及授權界線見 research/sources.md。

參考來源｜S11–S15

S11 • Linear Models（實驗版本核對）

URL：https://scikit-learn.org/1.6/modules/linear_model.html

作者／組織：scikit-learn developers

日期：版本 1.6.1 文件；查閱 2026-10-20。

主題：核對使用者研究整理的 OLS、Ridge、Lasso、分位數與求解器適用範圍。

S12 • Feature selection（實驗版本核對）

URL：https://scikit-learn.org/1.6/modules/feature_selection.html

作者／組織：scikit-learn developers

日期：版本 1.6.1 文件；查閱 2026-10-20。

主題：KBest、RFE 與模型選擇。

S13 • Common pitfalls（實驗版本核對）

URL：https://scikit-learn.org/1.6/common_pitfalls.html

作者／組織：scikit-learn developers

日期：版本 1.6.1 文件；查閱 2026-10-20。

主題：Pipeline、防洩漏與隨機性。

S14 • scikit-learn 線性模型估計器與求解器技術選型指南

作者／組織：使用者提供，使用者說明為 NotebookLM 研究整理。

日期：2026-10-20 收件；實際研究日期未提供。

主題：研究摘要原始附件；13 頁。

本地檔案：research/notebooklm_chat.pdf。

S15 • HW2 對話內容整理與實作提示詞存檔

作者／組織：使用者提供之 ChatGPT 整理稿。

日期：文件標示製作日期 2026-10-20。

主題：作業需求、特徵數限制、研究與實作提示詞；4 頁。

本地檔案：research/chatgpt_session.pdf。

詳細發現、與作業的關係及授權界線見 research/sources.md。

參考來源｜S16–S18

S16 · 第二題：House Sales in King County, USA

URL：https://www.kaggle.com/datasets/harlfoxem/housesalesprediction

作者／組織：harlfoxem / Kaggle

日期：version 1，2016-08-25（Kaggle API metadata）

主題：房屋成交價多元回歸；19 個原始輸入特徵。

S17 · Using custom workflows with GitHub Pages

URL：https://docs.github.com/en/pages/getting-started-with-github-pages/using-custom-workflows-with-github-pages

作者／組織：GitHub Docs。

日期：未提供固定出版日期；查核 2026-10-28。

主題：GitHub Actions 靜態網站建置與 Pages 發布。

S18 · Deploy a FastAPI App

URL：https://render.com/docs/deploy-fastapi

作者／組織：Render。

日期：未提供固定出版日期；查核 2026-10-28。

主題：FastAPI Web Service 部署。

詳細發現、與作業的關係及授權界線見 research/sources.md。

附錄｜重現設定與檔案索引

Python：3.9.12 (main, Mar 29 2023, 09:45:36)

套件	實際版本
numpy	1.24.2
pandas	2.3.3
scikit-learn	1.6.1
scipy	1.13.1
statsmodels	0.14.6
matplotlib	3.9.4
joblib	1.5.3
PyMuPDF	1.26.5
nbformat	5.9.0
nbclient	0.8.0
pytest	8.4.2
requests	2.32.5

固定種子：42；CV 五折；KBest/RFE k=5,10,15；LassoCV 三折內層，12 個候選 alpha。精確 estimator 參數保存在 selection_lock.json 及 environment.json。完整來源碼在 src/，Notebook 直接呼叫同一套模組，不維護相互矛盾的實作。

執行：python -m src.run_experiment；測試：python -m pytest -q；重建報告：python scripts/build_report.py；驗收打包：python scripts/validate_and_package.py。先依 README 安裝 requirements.txt 並取得字型與資料。

原始資料雜湊（train.csv）：6c9adeacec0537306a80b957a69e57bf6d389e3c02c1ff33ca0a7dcb5a9b30fb

欄位、係數、OLS HC3、VIF、失敗案例與所有 CV fold 均有獨立 CSV。圖表以 PNG 保存，方便老師重看；PDF 不依賴 Notebook 才能閱讀。